



Master Monnaie Banque Finance Assurance

Parcours Analyse des risques bancaires

Projet d'Économétrie Appliquée

**Analyse Univariée & Multivariée du cours de l'action
Total et Analyse des déterminants des souscriptions
au dépôts à termes selon le modèle Logit-Probit**

Réalisé par :

Mohamed RADOUAN

Ilias OUARDIRHI

Manyl AOURANE

Sous la direction de :

Mme Françoise Seyte

Année universitaire : 2024/2025

1 Sommaire

Remerciements	2
Résumé	3
Chapitre 1 : Étude univariée du cours de l'action Total	4
Introduction	4
Analyse du cours de l'action Total	5
Prévision	9
Conclusion	17
Chapitre 2 : Étude multivariée des cours de l'action Total, du Brént et du CAC40	18
Introduction	18
Analyse des chroniques	18
Le modèle Vector Auto Regressive (VAR)	24
Causalité au sens de Granger	29
Causalité au sens de Sims	30
Modèle à correction d'erreur vectorielle (VECM)	32
Conclusion	33
Chapitre 3 : Étude sur les Déterminants de Souscription aux Dépôts à Termes	35
Introduction	35
Données et Analyse Descriptives	35
Analyse de la Corrélation entre les variables	39
Modélisation	41
Conclusion	45
Bibliographie/Webographie	46
Annexes	47
Table des matières	63

2 REMERCIEMENTS

Nous tenons à exprimer notre profonde gratitude à Madame Françoise Seyte, professeure et maître de conférences à l'Université de Montpellier, pour la qualité de son enseignement et le soutien précieux qu'elle nous a apporté tout au long de l'année.

3 RESUME

Le but de cette étude est de réaliser trois analyses distinctes focalisées sur les variables suivantes : le cours de Total, le cours du Brent, le cours du CAC40 et les souscriptions au dépôts à terme. Notre projet comprendra alors une analyse univariée et une analyse multivariée sur les variables des actions cotées en Bourse et la dernière analyse se concentrera particulièrement une partie sur l'étude des déterminants des souscriptions au dépôts à terme grâce au modèle Logit-Probit.

La première partie est dédiée à l'analyse univariée du cours de Total. Elle consiste en un examen approfondi de la série temporelle des prix de l'action couvrant la période allant de Octobre 2013 à Octobre 2023. La base de données est mensuelle et a été extraite du site financier Yahoo Finance. L'objectif est de prédire les tendances futures de ces prix pour l'année 2024. Pour atteindre cet objectif, une série de tests statistiques a été employée pour identifier la nature de la série temporelle et ses composants. Ensuite, la méthodologie de Box et Jenkins a été mise en oeuvre, permettant d'abord une exploration approfondie de la série temporelle, puis une prévision pour l'année 2024.

La seconde partie de notre analyse propose une analyse multivariée des cours du Brent et du CAC 40 et de l'action Total. En effet, nous avons importé les données mensuelles allant de Octobre 2013 à Octobre 2023 sur Yahoo Finance pour ces trois séries financières afin de mener à bien notre étude. L'objectif est de décrypter le marché des matières premières en explorant les interactions entre les prix de ces variables. Nous employons le modèle VAR (Vector AutoRegression) pour analyser les interrelations et les rétroactions. De plus, des outils d'analyse de la causalité entre ces variables sont employés pour déceler les interdépendances et prévoir les dynamiques futures des prix de ces ressources essentielles afin d'analyser les influences du marché des matières premières.

La dernière partie de notre analyse consiste en l'analyse des déterminants des souscriptions aux dépôts à terme en utilisant les modèles Logit et Probit. Ces modèles permettent d'expliquer la probabilité qu'un client souscrive un dépôt à terme en fonction de différentes variables explicatives, tout en modélisant cette relation de manière statistique. L'objectif est de mieux comprendre les facteurs influençant ces souscriptions et d'estimer leur impact à partir des données disponibles.

4 Chapitre 1 : Etude univariée du cours de l'action Total

4.1 INTRODUCTION

Les séries temporelles constituent un outil incontournable pour l'analyse des phénomènes économiques et financiers, car elles capturent les variations d'une variable dans le temps, qu'il s'agisse de jours, de mois, ou d'années. Leur modélisation permet de mieux comprendre les dynamiques sous-jacentes et, surtout, de prévoir les évolutions futures. Ces prévisions sont cruciales dans un environnement économique marqué par l'incertitude et les perturbations externes, où les entreprises doivent constamment s'adapter aux fluctuations du marché.

Dans ce projet, nous nous intéressons aux données de **TotalEnergies**, un leader mondial du secteur énergétique. Ce choix est motivé par l'importance stratégique du secteur de l'énergie dans l'économie mondiale et son exposition aux facteurs externes tels que les variations des prix du pétrole, les politiques énergétiques et les événements géopolitiques. L'analyse se concentre sur une série temporelle univariée, avec pour objectif principal de modéliser son comportement historique et d'en extraire des prévisions fiables.

Le contexte récent, marqué par des incertitudes géopolitiques, des perturbations dans les chaînes d'approvisionnement et une transition énergétique accélérée, renforce l'intérêt d'une telle étude. Les séries temporelles liées à une entreprise comme TotalEnergies offrent une opportunité unique d'explorer comment ces facteurs impactent l'évolution des indicateurs clés, tels que la consommation énergétique, les cours des produits pétroliers, ou encore les revenus.

Dans cette perspective, notre étude répond à la problématique suivante : **Comment modéliser et prévoir les variations des séries temporelles liées aux données de TotalEnergies à l'aide des méthodes d'analyse univariée, notamment celle de Box et Jenkins ?**

Pour répondre à cette problématique, l'étude s'articule autour de deux axes principaux. Dans un premier temps, une analyse descriptive et exploratoire sera réalisée afin de caractériser la série temporelle, en identifiant des aspects tels que la tendance, la saisonnalité, et la stationnarité. Dans un second temps, des techniques d'économétrie avancées, notamment les modèles ARIMA, seront appliquées pour produire des prévisions robustes. Ces résultats permettront de mieux comprendre la dynamique des données étudiées et d'apporter des éléments pertinents pour la prise de décision stratégique dans le secteur énergétique.

4.2 ANALYSE DU COURS DE L'ACTION TOTAL

4.2.1 Analyse descriptive

Les données utilisées proviennent de la plateforme financière *Yahoo Finance*, reconnue pour fournir des informations fiables et détaillées sur les cotations boursières.

L'objet étudié est le cours mensuel des actions de **TotalEnergies**. Les données couvrent la période allant du 1er janvier 2014 au 1er octobre 2024. Ces données, téléchargées et structurées pour constituer la base d'analyse, sont complètes et adaptées à une étude rigoureuse des séries temporelles.

La méthodologie adoptée s'articule autour de deux étapes principales. Dans un premier temps, une analyse descriptive des données est réalisée pour mettre en lumière les principales caractéristiques de la série, telles que la tendance et la saisonnalité. Cette étape inclut également des tests statistiques pour évaluer la stationnarité et détecter d'éventuelles composantes stochastiques ou déterministes.

Dans un second temps, la modélisation et la prévision sont effectuées à l'aide de la méthode de Box et Jenkins, en appliquant des modèles ARIMA adaptés aux données. Les prévisions sont réalisées pour la période allant d'octobre 2023 à octobre 2024, permettant d'anticiper l'évolution des cours mensuels de TotalEnergies. Les performances des modèles sont ensuite évaluées à l'aide d'indicateurs standards, afin de garantir la robustesse et la fiabilité des prévisions obtenues.

L'étude repose sur des outils statistiques rigoureux, en adoptant un seuil critique de 5 % pour les tests d'hypothèses. Elle vise à fournir une analyse complète et précise, combinant une compréhension approfondie des données historiques et des projections futures.




Figure 1: Évolution du cours mensuel de TotalEnergies (01/2014 - 10/2024)

L'observation du graphique permet de constater que l'évolution des cours de l'action TotalEnergies (TTEF) reflète les dynamiques économiques et les fluctuations des marchés énergétiques sur la période 2014-2024. Tout d'abord, on remarque qu'entre 2014 et 2019, les cours restent relativement stables, oscillant entre 40 et 50 EUR, ce qui témoigne d'une certaine résilience de l'entreprise face aux variations modérées des prix du pétrole.

En 2020, l'impact de la crise sanitaire mondiale liée à la pandémie de COVID-19 se traduit par une chute brutale des cours, atteignant un niveau historiquement bas d'environ 25 EUR. Cependant, dès 2021, une reprise progressive s'amorce, portée par la relance économique mondiale et l'augmentation des prix de l'énergie. Cette tendance haussière culmine en 2022, avec des cours atteignant jusqu'à 68 EUR, reflétant les bénéfices tirés de la hausse du prix du pétrole. Enfin, la période récente (2023-2024) est marquée par une stabilisation des cours, évoluant entre 55 et 65 EUR, signe de la résilience et de la capacité d'adaptation de TotalEnergies dans un contexte de volatilité des marchés énergétiques.

Table 1: Statistiques des Prix (DERNIER_TTEF)

Statistiques	DERNIER_TTEF
Moyenne	47.61
Médiane	47.09
Écart-Type	8.16
Min	25.82
Max	68.59
Skewness	0.17
Kurtosis	3.03
Jarque-Bera	0.59 (p = 0.74)
Observations	130

L'analyse des résultats révèle une moyenne de 47.61, ce qui signifie qu'entre 2014 et 2024, le cours de Total se situe généralement autour de cette valeur. La médiane, légèrement inférieure à la moyenne (47.09), indique que la majorité des prix sont proches de cette valeur, bien qu'il existe quelques variations plus marquées.

L'écart-type de 8.16 montre qu'il y a une certaine dispersion des prix autour de la moyenne, suggérant des fluctuations notables mais sans excès. En effet, les prix varient entre un minimum de 25.82 et un maximum de 68.59, illustrant ainsi une plage relativement large. L'asymétrie des données, mesurée par une skewness de 0.17, est faible, ce qui signifie que la distribution des prix est presque symétrique, avec quelques prix légèrement plus élevés que la moyenne. La kurtosis de 3.03 suggère que la distribution est proche d'une distribution normale, sans pics ou queues excessivement marqués. Enfin, le test de Jarque-Bera, avec une p-value de 0.74, indique que la distribution des prix ne diffère pas de manière significative d'une distribution normale.

4.2.2 Test d'hétéroscédasticité

Tout d'abord, un test d'hétéroscédasticité sera effectué (**Test ARCH**) afin de tester la présence, ou non, d'hétéroscédasticité dans notre série, responsable des fortes fluctuations du cours.

Test d'homoscédasticité (ARCH) : (Annexe: Figure 16)

- Hypothèses :

- H_0 : Homoscédasticité
- H_1 : Hétéroscédasticité

- Statistique de test :

$$LM = 91,79 > \chi^2(5) = 11.07$$

- Règle de décision :

La statistique du multiplicateur de Lagrange est comparée à la valeur critique de la distribution du Khi-deux ayant pour degrés de liberté 5.

Dans notre cas, la statistique de test est supérieure à la valeur critique, ce qui signifie qu'on rejette l'hypothèse nulle à un risque de 5%. Il y a donc une présence d'hétéroscédasticité dans notre série.

Il convient alors de passer par une transformation logarithmique, afin de réduire l'ampleur des fluctuations de la série.

Nous travaillerons à présent sur le logarithme du cours de Total Énergie, noté **LTOTAL**. Ci-dessous un graphique représentant l'évolution du cours de Total Énergie sur les 10 dernières années (en bleu), et l'évolution du logarithme du cours de Total Énergie (en rouge).




Figure 2: Évolution du cours de Total Énergie et de son logarithme (LTOTAL).

Passons ensuite à l'analyse de la variance et aux tests de Fisher afin de tester la présence, ou non, de saisonnalité, et de tendance.

4.2.3 Analyse de la saisonnalité et de la tendance

Afin de tester la présence de saisonnalité et de tendance dans notre série, un tableau de Buys-Ballot, et un tableau de Buys-Ballot classé ont été effectués, indiquant les moyennes et écarts type mensuelles et annuelles. Ces valeurs sont utilisées afin de calculer les différentes variances (annuelle, mensuelle, résiduelle), dont les résultats sont affichés dans les tableaux ci-dessous :

Somme des carrés	Degrés de liberté	Désignation	Variance
$S_p = 0,006080562$	11	Variance annuelle	$V_p = 0,000552778$
$S_a = 0,462336622$	9	Variance mensuelle	$V_a = 0,051370736$
$S_r = 0,577335068$	119	Variance résiduelle	$V_r = 0,001100181$

Table 2: Analyse de la variance

Détection de la saisonnalité :

Le tableau de Buys Ballot classé nous donne une indication quant à la présence ou non d'une saisonnalité dans la série. À priori, aucun mois ne revient chaque année à la même position, ce qui laisse penser à une absence de saisonnalité. Un test de Fisher est effectué afin de confirmer cette hypothèse.

- **Hypothèses :**

- H_0 : La série n'est pas saisonnière
- H_1 : La série est saisonnière

- **Statistique de test :**

$$F_c = \frac{V_p}{V_r}$$

La statistique de test est comparée à la valeur critique de la distribution F de Fisher avec des degrés de liberté $(p - 1) = 11$ et $(n - 1)(p - 1) = 119$.

Dans notre cas :

$$F_c = 0,50244327 < F(11, 119) \approx 1,88$$

- **Règle de décision :**

La statistique de test est inférieure à la valeur critique, nous acceptons l'hypothèse nulle avec un risque de 5

Détection de la tendance :

Nous pouvons utiliser le graphique du cours de LTotal afin d'avoir une idée sur la présence ou non de tendance dans notre série.

- **Hypothèses :**

- H_0 : La série ne présente pas de tendance.
- H_1 : La série présente une tendance.

- **Statistique de test :** La statistique de test est comparée à la valeur critique de la distribution F de Fisher avec des degrés de liberté $(n-1) = 9$ et $(n-1)(p-1) = 119$.

Dans notre cas :

$$F_c = 46,69 > F(9, 119) \approx 1,97$$

- **Règle de décision :**

La statistique de test est supérieure à la valeur critique. Nous rejetons l'hypothèse nulle au risque de 5%, la série présente une tendance.

D'après nos résultats, la série LTotal présente une tendance, mais pas de saisonnalité. Nous pouvons alors passer aux méthodes de prévisions traditionnelles.

Analyse du corrélogramme

En se basant sur le corrélogramme (Annexe 5), on observe une décroissance progressive de la fonction d'autocorrélation (FAC), ce qui suggère la présence d'un processus non stationnaire. En revanche, la fonction d'autocorrélation partielle (FAP) présente un pic notable au premier décalage.

Ces observations indiquent la possibilité d'un processus AR(1), caractérisé par la décroissance exponentielle lente de la FAC et le pic observé au premier décalage de la FAP. Cependant, il est important de souligner que ce processus AR(1) potentiel n'est pas stationnaire. Si cette hypothèse se confirme, il sera nécessaire de rendre la série stationnaire pour poursuivre l'analyse.

4.3 PREVISION

4.3.1 Test de Stationnarité Dickey-Fuller

Le test de Dickey-Fuller (DF) est un outil statistique utilisé pour tester la stationnarité d'une série temporelle. Il s'appuie sur l'estimation de modèles autorégressifs afin de déterminer si la série présente une racine unitaire (et est donc non stationnaire). Nous utilisons trois modèles pour ce test :

- **Modèle sans constante et sans tendance (Modèle 1) :**

$$Y_t = \alpha Y_{t-1} + \epsilon_t \quad (1)$$

où Y_t est la série temporelle, α est le coefficient à estimer, et ϵ_t est le terme d'erreur.

- **Modèle avec constante (Modèle 2) :**

$$Y_t = C + \alpha Y_{t-1} + \epsilon_t \quad (2)$$

où C est la constante ajoutée au modèle pour capturer les variations autour d'une moyenne.

- **Modèle avec constante et tendance (Modèle 3) :**

$$Y_t = C + T + \alpha Y_{t-1} + \epsilon_t \quad (3)$$

où C est la constante et T représente un terme de tendance linéaire.

Résultats du Test de Dickey-Fuller

Les résultats du test pour les trois modèles sont résumés dans le tableau ci-dessous. La statistique de test est comparée aux valeurs critiques à un seuil de confiance de 5% afin de déterminer si l'hypothèse nulle de non-stationnarité peut être rejetée.

Ltotal	Statistique du test	Valeur critique (5%)	Conclusion
Modèle 1	0.34	-1.94	Non stationnaire
Modele 2	-1.1961	-2.8847	Non stationnaire
Modele 3	-1.6179	-3.4462	Non stationnaire

Table 3: Résultats du test de Dickey-Fuller pour les trois séries

Paramètre	Total
SCR_2^c	0.571064
SCR_2	0.554091
n	129
SCR_3	0.549064
SCR_3^c	0.569874
F_1	1.960458
F_2	1.696220
F_3	2.406705
Resultats	DS sans dérive

Table 4: Tableau des résultats pour Total

Interprétation des Résultats

Pour les trois modèles testés, la statistique de test est supérieure aux valeurs critiques de 5%, ce qui signifie que nous ne pouvons pas rejeter l'hypothèse nulle de non-stationnarité. Autrement dit, la série est non stationnaire dans les trois cas. Il sera donc nécessaire de réaliser des tests d'hypothèse jointe pour distinguer entre un processus de différence stationnaire (DS) et un processus stationnaire en tendance (TS).

La statistique F_1 est donnée par :

$$F_1 = \frac{(SCR_c - SCR_2)}{2} \div \frac{SCR_2}{129 - 2} < 4.71$$

Elle est inférieure à la valeur critique au seuil de $\alpha = 5\%$ (voir Table 3), ce qui nous conduit à accepter l'hypothèse H_0 à ce même niveau de confiance. De même, les hypothèses H_0^2 et H_0^3 sont acceptées, leurs statistiques étant respectivement :

$$F_2 = \frac{(SCR_c - SCR_3)}{3} \div \frac{SCR_3}{129 - 3} > 4.88$$

et

$$F_3 = \frac{(SCR3_c - SCR3)}{2} \div \frac{SCR3}{129 - 3} > 6.49$$

Ces valeurs sont supérieures aux seuils critiques correspondants.

Par ailleurs, après avoir effectué le test de nullité de la moyenne, il apparaît que la série des cours de Total suit un processus de différence stationnaire (DS) sans dérive, caractérisé par la relation :

$$\Delta x_t = a_t$$

où a_t représente un terme d'erreur blanc. Cela suggère que les variations des cours de Total sont stationnaires après différenciation, sans tendance sous-jacente.

4.3.2 Test de Phillips-Perron

Les tests de Phillips-Perron ont le même objectif que les tests de Dickey-Fuller (simple ou augmenté). Cependant, les tests de Phillips-Perron permettent d'intégrer les erreurs hétéroscédastiques et autocorrélés simultanément. Ces tests servent à admettre ou non dans le modèle testé la présence de racine unitaire. Ainsi, les trois modèles testés sont de la forme suivante :

- **Hypothèses:**

l'hypothèse nulle (H_0) présence d'une racine unitaire $\Phi_1 = 1$

l'hypothèse alternative (H_1) absence de racine unitaire, soit $\Phi_1 < 1$

Résultats du Test de Phillips-Perron (c.f : Annexe figure 11 a 13)

Les résultats de ce test sont résumés dans le tableau ci-dessous, dans lequel on compare les valeurs critiques au seuil statistique du test:

Modèle	Statistique du test	Valeur critique (5%)	Conclusion
Modèle 1	0,574560	-1,943324	Non stationnaire
Modèle 2	-1,694203	-2,883930	Non stationnaire
Modèle 3	-1,942187	-3,445030	Non stationnaire

Table 5: Résultats du Test de Phillips-Perron pour les trois modèles

Test de Phillips-Perron sur le modèle 3 :

On observe que la valeur calculée de la t-statistique $t(\Phi)$ est de $-1,942187$. Par conséquent, elle est significativement supérieure à la valeur critique au seuil $\alpha = 0,05$, égale à $-3,445030$ (*annexe 1*). Comme pour les modèles précédents, l'hypothèse nulle de présence de racine unitaire est acceptée. Par conséquent, la série est non-stationnaire.

Test de Phillips-Perron sur le modèle 2 :

On observe que la valeur calculée de la t-statistique $t(\Phi)$ est de $-1,694203$. Par conséquent, elle est significativement supérieure à la valeur critique au seuil $\alpha = 0,05$ égale à $-2,883930$ (*annexe 2*). Comme pour les modèles précédents, l'hypothèse nulle de présence de racine unitaire est acceptée. Donc, la série est non-stationnaire.

Test de Phillips-Perron sur le modèle 1 :

On observe que la valeur calculée de la t-statistique $t(\Phi)$ est de 0,574560. Par conséquent, elle est significativement supérieure à la valeur critique au seuil $\alpha = 0,05$ égale à $-1,943324$ (annexe 3). Comme pour les modèles précédents, l'hypothèse nulle de présence de racine unitaire est acceptée. Donc, la série est non-stationnaire.

4.3.3 Test BDS

Le test BDS a été établi par Brock, Dechert et Scheinkman. C'est un test de détection de dépendance non-linéaire dans la série. Il permet d'affirmer la présence ou non de processus stochastique non linéaire.

- **Hypothèses :**

H_0 : Indépendance des résidus

H_1 : Dépendance des résidus

- **Règle de décision :**

Si la valeur absolue de la statistique du test BDS (*z-statistic*) est inférieure à 1,96 (valeur de la loi normale pour un test bilatéral à 5%), ou si la probabilité associée à la statistique de test est supérieure à 0,05, alors on accepte l'hypothèse nulle d'indépendance. Le processus générateur de la série est linéaire.

Si la valeur absolue de la statistique du test BDS (*z-statistic*) est supérieure à 1,96 (valeur de la loi normale pour un test bilatéral à 5%), ou si la probabilité associée à la statistique de test est inférieure à 0,05, alors on rejette l'hypothèse nulle d'indépendance. Le processus générateur de la série est non linéaire.

Résultats du Test BDS (c.f : Annexe figure 14)

Dimensions	z-statistic	Prob
2	21,36967	0,0000
3	22,92657	0,0000
4	24,00215	0,0000
5	25,51337	0,0000
6	27,81797	0,0000

Figure 3: Tableau présentant les résultats du test BDS (annexe 4)

Nous observons que les *z-statistic* sont supérieures à 1,96. Par conséquent, on en déduit que le processus générateur de la série est non linéaire. Il est donc nécessaire d'utiliser les processus *Auto-Regressive Conditional Heteroskedasticity* (ARCH) pour prendre en compte cette non-linéarité.

Résultats du Test ARCH

À la suite des examens précédents, il est impératif de caractériser deux processus distincts : d'une part, le processus AutoRegressive-Moving-Average (ARMA), qui intègre la structure linéaire de la chronique, et d'autre part, le processus relevant de la classe AutoRegressive Conditional Heteroskedasticity (ARCH).

Il s'agit d'une classe de processus (ARCH, TARCH, GARCH, etc.) permettant de modéliser la non-linéarité dans la chronique. En effet, la non-linéarité dans une série est due à la forte hétéroscédasticité des résidus, ce qui n'est pas favorable à l'obtention de résultats significatifs de prévision dès lors qu'elle n'est pas éliminée de la chronique.

Le premier processus ARCH(p) est introduit par Robert Engle en 1982. Il cherche à modéliser le processus générateur de la série temporelle $\epsilon_t = \sigma_t w_t$. Le processus ARCH(p) considère que la variance du terme d'erreur à la date t est une fonction du carré des termes d'erreurs des dates précédentes. La détermination du processus ARCH adéquat est faite de manière séquentielle. C'est-à-dire que dans un premier temps, il faut estimer un ARCH(1) puis vérifier les propriétés de ses résidus.

Si ces derniers sont homoscedastiques, ledit ARCH(1) est sélectionné. Si cependant les résidus ne sont pas homoscedastiques, il faut passer au ARCH(2), puis au ARCH(3), ainsi de suite, et prévoir passer à des modèles améliorés tels que le GARCH, le TARCH, le TGARCH, ou le EGARCH, etc. Il est important de préciser que les coefficients des paramètres de l'équation de la variance issus d'une modélisation ARCH doivent respecter, au-delà d'être significatifs, des conditions de positivité et de stationnarité.

- Chaque coefficient > 0
- $\sum \text{coefficients} < 1$

Après estimations, le modèle ARCH (1) est choisi.

Variation Equation	Coefficient	Prob
C	0,002883	0,0000
RESID(-1) ²	0,382528	0,0007

F-statistic	0,387833
Obs*R-squared	2,418899
Prob.F(6 ; 116)	0,8856
Prob.Chi-square (6)	0,8774

Figure 4: Tableau présentant les résultats de l'estimation du modèle ARCH (1)

Nous observons que les paramètres du modèle ne sont pas significatifs.

Test d'homoscédasticité du modèle ARCH (1) (c.f : Annexe figure 15)

Nous observons également que la prob.Chi-square(6) est égale à 0,8774 et donc supérieure à 0,0007. Cela implique la présence d'homoscédasticité dans le modèle (annexe 6). En conséquence, il n'est pas nécessaire d'aller plus loin dans l'analyse des modèles ARCH, GARCH...

4.3.4 Identification du processus

À la suite des examens précédents, il est impératif de caractériser deux processus distincts : d'une part, le processus AutoRegressive-Moving-Average (ARMA), qui intègre la structure linéaire de la chronique, et d'autre part, le processus relevant de la classe AutoRegressive Conditional Heteroskedasticity (ARCH), qui prend en compte la structure non linéaire.

Test ARCH d'hétéroscédasticité (c.f : Annexe figure 17)

Dans le cadre de ce test, nous allons vérifier si notre série temporelle est homoscedastique, c'est-à-dire si la variance de l'erreur est la même pour toutes les observations. Pour ce faire, nous allons réaliser le test d'hétéroscédasticité de ARCH.

- **Hypothèses :**

- H_0 : Homoscedasticité de la chronique
- H_1 : Hétéroscédasticité de la chronique

- **Statistique de test :** La statistique de test est donnée par :

$$LM = n \times R^2$$

où n est le nombre d'observations et R^2 est le coefficient de détermination. La statistique LM suit la loi du Khi-deux avec p degrés de liberté.

- **Règle de décision :**

- Si $n \times R^2 < \chi^2(p)$ ou si la probabilité associée est supérieure à 0,05, alors on accepte l'hypothèse nulle H_0 d'homoscedasticité.
- Si $n \times R^2 > \chi^2(p)$ ou si la probabilité associée est inférieure à 0,05, alors on rejette l'hypothèse nulle et on accepte l'hypothèse alternative H_1 d'hétéroscédasticité.

Test de normalité de Jarque-Bera (c.f : Annexe figure 10)

Ce test nous permet de tester la normalité des résidus. La statistique de ce test est basée sur le multiplicateur de Lagrange.

- **Hypothèses :**

- H_0 : Les résidus sont distribués selon la loi normale
- H_1 : Les résidus ne sont pas distribués selon la loi normale

- **Règle de décision :**

- Si la statistique de Jarque-Bera est inférieure à $\chi^2(2)$, c'est-à-dire 5,99, alors l'hypothèse nulle H_0 est acceptée.
- Si la statistique de Jarque-Bera est supérieure à $\chi^2(2)$ (5,99), alors l'hypothèse nulle H_0 est rejetée.

Test d'autocorrélation de Ljung-Box (c.f : Annexe figure 9)

Le test de Ljung-Box permet de déterminer si les résidus sont autocorrélés, c'est-à-dire si les observations actuelles dépendent des valeurs passées à plusieurs retards.

- **Hypothèses :**

- H_0 : Absence d'autocorrélation des résidus
- H_1 : Présence d'autocorrélation des résidus

- **Règle de décision :**

- Si la probabilité est inférieure à 5%, alors l'hypothèse nulle H_0 est rejetée.
- Si la probabilité est supérieure à 5%, alors l'hypothèse nulle H_0 est acceptée.

Choix du processus optimal ARMA (c.f : Annexe figure 21 a 24)

Dans l'objectif de déterminer le modèle le plus optimal, nous allons comparer les différents processus selon les critères de qualité des résidus, le R^2 , le critère d'Akaike et la significativité des paramètres.

	MA	1	2	3	4	5
AR		-2.564931	-2.577811	-2.576785	-2.578804	2.563401
1	-2.560554	-2.558877	-2.587326	-2.572027	-2.563347	-2.547829
2	-2.577765	-2.586803	-2.572126	-2.556623	-2.623971	-2.609258
3	-2.575970	-2.572397	-2.557142	-2.540785	-2.609439	-2.605494
4	-2.578080	-2.563665	-2.619174	-2.604151	-2.595562	-2.590007
5	-2.564608	-2.549334	-2.603905	-2.604825	-2.585927	-2.583862

Table 6: Tableau des valeurs AR et MA

Modèle	Significativité	Akaike	Homoscedasticité	Normalité	Autocorrelation	R^2
ARMA(2,1)	Oui	-2.586803	Oui	Non	Oui	0.06
ARMA(3,1)	Oui	-2.572397	Oui	Non	Oui	0.06
ARMA(2,4)	Non	-2.623971	Oui	Non	Oui	0.17
ARMA(4,2)	Non	-2.619174	Oui	Non	Oui	0.16
ARMA(5,2)	Non	-2.603905	Oui	Non	Oui	0.16

Table 7: Tableau des résultats des modèles

Au final, le modèle ARMA(2,1) semble être le plus optimal car :

- Il minimise le critère d'Akaike.
- Il possède des paramètres significatifs.

Les autres modèles, bien que présentant un critère d'Akaike et un R^2 plus élevés que le modèle ARMA(2,1), ne sont pas retenus en raison de l'absence de significativité de leurs paramètres. Cela souligne l'importance de prendre en compte l'ensemble des tests effectués sur les différents modèles, car la qualité des résidus ne permet pas de les différencier de manière concluante par rapport au modèle ARMA(2,1).


4.3.5 Prédiction du cours de l'action Total

La prévision a été réalisée en utilisant un modèle ARMA(2,1). Les résultats obtenus correspondent aux différents cours prévus de l'action Total, qui ont été comparés aux cours réels observés sur le marché. La transformation des données a été effectuée en utilisant l'équation suivante : $\text{difln}(Total)_t = \ln(Total)_t - \ln(Total)_{t-1}$.

Cette transformation permet de reconstituer les valeurs prédites grâce à la relation $\ln(Total)_t = \text{difln}(Total)_t + \ln(Total)_{t-1}$. Ensuite, les valeurs finales sont obtenues en appliquant l'exponentiation : $(Total)_t = e^{\ln(Total)_t}$. Ainsi, $\ln(Total)_t$ représente les prévisions exprimées en logarithmes, tandis que $(Total)_t$ correspond aux valeurs finales après conversion. Les résultats finaux incluent une comparaison entre les prévisions corrigées de la série chronologique et les valeurs réelles du marché, permettant ainsi une évaluation précise de la qualité des prévisions.

Date	DI Total Prévu	LT Total Prévu	Total Prévu	Total Observé
Oct-23	0.014182	4.146304	63.199981	63.20
Nov-23	-0.001629	4.144675	63.097112	62.26
Dec-23	-0.001924	4.142751	62.975830	61.60
Jan-24	0.001977	4.144728	63.100456	60.10
Feb-24	-0.001199	4.143529	63.024844	58.99
Mar-24	0.000540	4.144069	63.058887	63.47
Apr-24	-0.000172	4.143897	63.048042	68.59
May-24	0.0000182	4.143915	63.049189	67.01
Jun-24	0.0000247	4.143940	63.050746	62.33
Jul-24	-0.0000247	4.143915	63.049189	62.48
Aug-24	0.0000148	4.143930	63.050122	62.19
Sep-24	-0.0000066	4.143923	63.049704	58.50
Oct-24	0.0000021	4.143925	63.049835	62.65

Table 8: Prévisions et observations des cours Total



La comparaison entre les valeurs **Total Prévu** et **Total Observé** révèle des performances de prévision variées du modèle ARMA(2,1). Dans certains mois, comme **Octobre 2023** et **Mars 2024**, les prévisions sont extrêmement proches des valeurs réelles, avec des écarts minimes, ce qui montre une bonne adéquation du modèle pour ces périodes.

Cependant, d'autres mois, tels que **Avril 2024** et **Septembre 2024**, montrent des écarts significatifs, où les prévisions sont largement inférieures aux valeurs observées. Ces différences pourraient être dues à des facteurs externes ou des événements imprévus affectant le marché, non capturés par le modèle.

Malgré ces écarts, le modèle montre une capacité générale à prévoir correctement les tendances, avec de petites erreurs sur certaines périodes. Néanmoins, les résultats suggèrent qu'une amélioration du modèle, peut-être en intégrant davantage de facteurs explicatifs ou en testant d'autres approches de prévision, pourrait être bénéfique pour mieux gérer les variations imprévues du marché.

4.4 Conclusion

L'objectif de cette première partie de notre projet est de prévoir l'évolution du cours de Total pour la période d'octobre 2023 à décembre 2024. Pour ce faire, nous avons utilisé la méthode de prévision de Box et Jenkins. Cette approche implique des transformations sur la série des cours, suivies de l'identification de la nature de la série chronologique afin de représenter correctement l'évolution de ces cours, tout en tenant compte des structures linéaires et non linéaires qui composent la série. Après avoir réalisé des tests statistiques et comparé les différents modèles, nous avons conclu que le modèle ARMA(2,1) fournit les prévisions les plus précises. En effet, les prévisions basées sur ce modèle se sont avérées fiables pour les mois d'octobre 2023 et mars 2024.

Ces résultats soulèvent la question suivante : dans quelle mesure l'intégration d'autres variables explicatives, telles que celles provenant de Brent et du CAC 40, pourrait améliorer la précision des prévisions pour Total dans un contexte multivarié ? Cette réflexion nous conduit à explorer, dans la prochaine étape de notre étude, l'impact des interactions entre Total, Brent et CAC 40, en vue d'affiner les prévisions sur une période plus longue et de mieux saisir les relations complexes entre ces variables.

5 Chapitre 2 : Etude multivariée des cours de l'action Total, du Brent et du CAC40

5.1 Introduction

Dans le contexte actuel des marchés financiers, comprendre les interactions entre différentes variables économiques est essentiel pour mieux prédire les tendances futures. En 2024, analyser les relations entre le cours de Total, le cours du Brent et l'indice CAC 40 est particulièrement pertinent pour éclairer les dynamiques qui façonnent les marchés des matières premières et des actions. Ces trois indicateurs clés jouent un rôle central dans leurs secteurs respectifs : Total pour l'industrie pétrolière, le Brent pour les matières premières, et le CAC 40 pour les marchés boursiers français. Ces liens peuvent révéler des influences mutuelles importantes, mais les relations entre ces variables restent souvent complexes et difficiles à interpréter.

Cette complexité soulève une question : **comment les interactions entre le cours de Total, le cours du Brent et l'indice CAC 40 influencent-elles les évolutions des marchés des matières premières et des actions en 2024 ?** Pour y répondre, il est nécessaire d'adopter une méthodologie différente des approches classiques de prévision.

Les modèles ARMA (p, q), issus de la méthodologie Box et Jenkins, sont traditionnellement utilisés pour analyser les séries temporelles. Cependant, ils présentent des limites lorsqu'il s'agit de prendre en compte des relations dynamiques entre plusieurs variables. Ces limites justifient le recours au modèle VAR (Vector Autoregression), qui permet d'étudier simultanément plusieurs séries temporelles et leurs interactions.

Dans cette étude, nous commencerons par analyser séparément les caractéristiques de chaque série temporelle, à savoir le cours de Total, le cours du Brent et l'indice CAC 40. Ensuite, nous utiliserons le modèle VAR pour modéliser les relations entre ces variables et examiner leurs interdépendances. Enfin, un test de causalité au sens de Granger sera réalisé pour identifier les influences que ces trois indicateurs exercent les uns sur les autres. Cette démarche permettra de mieux comprendre les interactions entre ces variables stratégiques et d'apporter des éléments de réponse à notre problématique.

5.2 Analyse des chroniques




Figure 5: Cours du Brent, du CAC 40, et de Total après transformation logarithmique

Prix du Brent

Le prix du Brent a connu une volatilité marquée au cours des dernières années, avec des variations importantes, tant à la hausse qu'à la baisse. Au début de l'année 2014, le Brent se maintenait à un niveau relativement élevé, avoisinant les 110 USD, soutenu par une demande solide et des tensions géopolitiques. Cependant, en 2020, l'impact de la pandémie de COVID-19 a provoqué une chute spectaculaire des prix, avec une baisse significative sous les 25 USD en avril.

Après cette chute, les prix ont rebondi entre 2021 et 2022, atteignant des niveaux supérieurs à 120 USD, alimentés par des tensions géopolitiques, notamment la guerre en Ukraine, ainsi que par des incertitudes sur les marchés mondiaux. En 2023 et 2024, bien que les prix soient relativement plus stables, une légère tendance à la baisse s'est installée, oscillant autour de 70-80 USD, marquée par un ajustement des attentes du marché en réponse à une croissance économique plus lente et à la gestion de l'offre.

Indice CAC40

L'indice CAC 40, représentant les 40 plus grandes entreprises cotées en France, a été influencé par les dynamiques économiques mondiales, affichant des fluctuations marquées en fonction des événements économiques majeurs. Entre 2014 et 2019, l'indice a évolué de manière relativement stable, oscillant entre 4 000 et 6 000 points, soutenu par une économie française robuste et la confiance des investisseurs. Cependant, avec la pandémie de COVID-19 en mars 2020, l'indice a chuté brusquement à environ 4 000 points, en raison des incertitudes économiques mondiales.

Cette baisse a été suivie d'une forte reprise dès fin 2020, portée par les politiques de soutien économiques et la reprise rapide, permettant à l'indice de dépasser les 7 000 points à la fin de 2021. Entre 2022 et 2024, l'indice est resté volatile, fluctuant entre 6 000 et 8 200 points, avec un sommet atteint en 2024, à 8 200 points, en raison d'une solide reprise économique et des résultats positifs des entreprises du CAC 40.

Les statistiques des prix pour le Brent et le CAC40 révèlent plusieurs points importants. Le prix moyen du Brent est de 69,63 USD, avec une médiane plus faible (67,06 USD), ce qui suggère une distribution légèrement biaisée vers des prix plus bas. L'écart-type du Brent (20,87) indique une volatilité relativement élevée, comparable à celle du CAC40 (1092,73), ce qui reflète des fluctuations importantes dans les deux séries.

Le prix du Brent a atteint un minimum de 22,74 USD et un maximum de 122,84 USD, tandis que le CAC40 a fluctué entre 4165,72 et 8205,81 points. Enfin, le test de Jarque-Bera pour le Brent ne montre pas de déviations significatives de la normalité ($p = 0,24$), alors que celui du CAC40 indique une distribution non normale ($p = 0,002$), suggérant une asymétrie ou une forte concentration autour de certaines valeurs.

Statistiques	DERNIER_BRENT	DERNIER_CAC40
Moyenne	69.63	5649.587
Médiane	67.06	5361.66
Écart-Type	20.87	1092.731
Min	22.74	4165.72
Max	122.84	8205.81
Skewness	0.31	0.6132
Kurtosis	2.61	2.18
Jarque-Bera	2.89 (p = 0.24)	11.77 (p = 0.002)
Observations	130	130

Table 9: Statistiques des Prix

5.2.1 Test d'hétéroscédasticité et analyse de la variance

Tout comme pour la série des cours de Total, un test d'hétéroscédasticité a été réalisé sur deux autres séries : les cours du Brent (Annexe 2) et du CAC 40 (Annexe 4). Ce test est suivi d'une analyse de la variance (Annexe 1 et 3), permettant d'examiner les éventuelles tendances ou saisonnalités dans les données. Les résultats obtenus pour les trois séries sont résumés dans le tableau ci-dessous :

	TOTAL	BRENT	CAC 40
Hétéroscédasticité	OUI	OUI	OUI
Tendance	NON	NON	NON
Saisonnalité	NON	NON	NON

Table 10: Résultats des tests d'hétéroscédasticité, de tendance et de saisonnalité des trois séries

Les tests montrent que toutes les séries présentent une hétéroscédasticité et une tendance significative, mais aucune d'elles ne révèle de saisonnalité.

Test de Stationnarité

Les résultats des tests pour les trois modèles sont présentés dans le tableau ci-dessous. La statistique de test est comparée aux valeurs critiques correspondant aux seuils de confiance de 5% , afin de déterminer si l'hypothèse nulle de non-stationnarité peut être rejetée.

Variable	Modèle	Statistique de test	Valeur critique (5%)	Résultat
TOTAL	Modèle 1	0,43	-1,94	Non stationnaire
	Modèle 2	-1,9	-2,88	Non stationnaire
	Modèle 3	-2,14	-3,44	Non stationnaire
BRENT	Modèle 1	-0,4	-1,94	Non stationnaire
	Modèle 2	-2,37	-2,88	Non stationnaire
	Modèle 3	-2,72	-3,44	Non stationnaire
CAC 40	Modèle 1	0,43	-1,94	Non stationnaire
	Modèle 2	-1,9	-2,88	Non stationnaire
	Modèle 3	-3,33	-3,44	Non stationnaire

Table 11: Résultats des tests de stationnarité des variables.

Pour les trois séries suivantes, la statistique de test dépasse les valeurs critiques à un seuil de 5%, ce qui implique que nous ne pouvons pas rejeter l'hypothèse nulle de non-stationnarité. En d'autres termes, les séries L_{total} , L_{brent} et L_{cac40} sont non stationnaires. Il sera donc nécessaire d'effectuer des tests d'hypothèse conjointe pour différencier un processus de différence stationnaire (DS) d'un processus stationnaire en tendance (TS)

Paramètre	Total	Brent	CAC40
SCR_2^c	0.571064	1.788191	0.284855
SCR_2	0.554091	0.277757	0.277757
n		129	
SCR_3^c	0.549064	1.678995	0.259454
SCR_3	0.569874	1.787448	0.282356
Nombre de lag		1	
F_1	1.960458	1.635502	2.868064
F_2	1.696220	4.144507	2.753213
F_3	2.406705	5.605144	4.101719
Résultats	DS sans dérive	DS sans dérive	DS sans dérive

Table 12: Tableau des résultats

Les résultats confirment que toutes les séries sont **non stationnaires**, comme indiqué par les tests de **Dickey-Fuller simple**.

Selon la simulation automatique du test sur *Eviews*, qui minimise les critères d'**Akaike** (AIC), de **Schwarz** (SIC) et de **Hannan-Quinn** (HQ), nous obtenons ces résultats :

- **1 retard** selon les critères (**AIC**) et (**HQ**) pour la série **LBrent**.
- **0 retard** selon les critères (**AIC**), (**SIC**) et (**HQ**) pour la série **LCAC40**.
- **0 retard** selon les critères (**SIC**) et (**HQ**) pour la série **LTotale**.

Le test de **Dickey-Fuller augmenté** doit alors être effectué sur la série **LBrent** afin de confirmer le résultat obtenu par le test de **Dickey-Fuller simple**

Test de Dickey-Fuller augmenté sur la série « **LBrent** » :

Le test de Dickey Fuller augmenté est semblable au test de Dickey Fuller simple, mais permet de prendre en compte l'autocorrélation potentielle des résidus en ajoutant des termes retardés à la régression. La stratégie de ce test est similaire à celle du test de Dickey Fuller simple, et les modèles à tester sont les suivants :

$$\text{Modèle [4]} : \Delta x_t = \rho x_{t-1} - \sum_{j=2}^p \Phi_j \Delta x_{t-j+1} + a_t$$

$$\text{Modèle [5]} : \Delta x_t = \rho x_{t-1} - \sum_{j=1}^p \Phi_j \Delta x_{t-j+1} + c + a_t$$

$$\text{Modèle [6]} : \Delta x_t = \rho x_{t-1} - \sum_{j=1}^p \Phi_j \Delta x_{t-j+1} + c + bt + a_t$$

Modèle 6

$H_0 : \phi_1 = 1$ Présence de racine unitaire;

$H_1 : |\phi_1| < 1$ Stationnarité du processus.

La valeur calculée de la T-stat obtenue est de -3,16, et est supérieure à la valeur critique au seuil $\alpha = 0,05$, qui vaut -3,44. Par conséquent, nous acceptons l'hypothèse nulle de **présence de racine unitaire**. (ANNEXE 5)

Hypothèse jointe 6 (c.f : Annexe figure 29)

$$H_0^6 : (c; b; \rho) = (c; 0; 0)$$

La statistique de Fisher associée à cette hypothèse est la suivante :

$$F_6 = \frac{(SCR_0 - SCR_6)/2}{SCR_6/(n - (p - 1) - 3)}$$

Avec :

- **SCRD** = somme des carrés des résidus du modèle 6 contraint par l'hypothèse H_0 = 1,749243 (c.f: Annexe figure 30)
- **SCR6** = somme des carrés des résidus du modèle 6 estimé par MCO = 1,611024

On obtient : $F_6 = 5,44 < F_{lue} = 6,49$ (c.f: Annexe figure 31)

La statistique de Fisher est inférieure à la valeur lue dans la table de Dickey Fuller, on accepte alors l'hypothèse H_0 au seuil $\alpha = 0.05$.

Hypothèse jointe 5

- $H_0^5 : (c; d; \rho) = (0; 0; 0)$

La statistique de Fisher associée à cette hypothèse est :

$$F_5 = \frac{(\mathbf{SCR}_c - \mathbf{SCR}_6)/3}{\mathbf{SCR}_6/(n - (p - 1) - 3)}$$

Avec :

- **SCRC** = somme des carrés des résidus du modèle 5 contraint par l'hypothèse H04 = 1,749842 (c.f: Annexe figure 32)

On obtient : $F_5 = 3,64 < \mathbf{F}_{lue} = 4,88$

La statistique de Fisher est inférieure à la valeur lue dans la table de Dickey Fuller, on accepte alors l'hypothèse H05 au seuil $\alpha = 0.05$.

Modèle 5 :

$$\hat{u}_t = \hat{c} + \hat{t}_t$$

$$H_1 : \hat{b}_1 < 1 \quad (\text{Présence de racine unité, Stationnarité du processus})$$

La valeur calculée de la t-stat est obtenue est de -2.76, et est supérieure à la valeur critique au seuil $\alpha = 0.05$, qui vaut -2.88. Par conséquent, nous acceptons l'hypothèse nulle de présence de racine unitaire. (c.f: Annexe figure 33)

Hypothèse jointe 4 :

$$H_0^4 : (c; \rho) = (0; 0)$$

La statistique de Fisher associée à cette hypothèse est :

$$F_4 = \frac{(\mathbf{SCR}_5 - \mathbf{SCR}_4)/2}{\mathbf{SCR}_4/(n - (p - 1) - 2)}$$

Avec :

$\mathbf{SCR}_5 = \sum$ des carrés des résidus du modèle 5 estimé par MCO = 1.683356 (cf. annexe, figure 34)

On obtient : $F_4 = 3.94 < \mathbf{F}_{lue} = 4.71$

La statistique de Fisher est inférieure à la valeur lue dans la table de Dickey Fuller, on accepte alors l'hypothèse H04 au seuil $\alpha = 0.05$.

Modèle 4 :

- La valeur calculée de la t-stat obtenue est de -0.50, et est supérieure à la valeur critique au seuil $\alpha = 0.05$, qui vaut -1.94. Par conséquent, nous acceptons l'hypothèse nulle de présence de racine unitaire. (c.f : Annexe figure 35)
- **Conclusion** : D'après la stratégie du test de Dickey Fuller augmenté, la série u_t échantillonnée présente une non-stationnarité de type I(1) sans dérive, il convient alors de la stationnariser en utilisant un filtre de différence première.

5.3 Le modèle Vector Auto Regressive (VAR)

Le modèle Vector Auto Regressive (VAR) est utilisé pour analyser des ensembles de données temporelles multiples, examine l'influence réciproque entre différentes séries au fil du temps. Il se base sur les historiques de ces séries pour évaluer comment chacune affecte et est affectée par les autres. Dans cette phase, on établit l'ordre du modèle VAR, qui sera maintenu tout au long du processus de modélisation. Cet ordre est sélectionné en fonction de sa capacité à minimiser le critère d'Akaike et Schwarz. Nous avons :

VAR(p)	1	2	3	4	5
Critère Akaike	-8,019132	-7,942375	-7,89738	-7,794263	-7,677919
Critère de Schwarz	-7,751754	-7,472076	-7,222075	-6,911828	-6,586197

Table 13: Critères Akaike et Schwarz pour différents ordres VAR(p)

Finalement, l'ordre du VAR choisi est 1 car il minimise les critères d'Akaike mais aussi les critères de Schwarz.

Test de significativité des coefficients

Pour tester la significativité, les t-statistics sont comparées en valeur absolue à la valeur critique 1,96.

Hypothèses du test

H_0 : Non significativité du coefficient

H_1 : Significativité du coefficient

Règle de décision

- Si la statistique du test t est inférieure à la valeur 1,96, alors on accepte l'hypothèse nulle de non significativité du coefficient.
- Si la statistique du test t est supérieure à la valeur 1,96, alors on rejette l'hypothèse nulle de non significativité du coefficient.

Nous constatons ici que tous les coefficients liés aux termes retardés ne présentent pas de signification statistique. Cela est dû au fait que la valeur absolue de la statistique t de Student pour ces coefficients est inférieure à la valeur critique correspondant à un seuil de signification de 5%, qui est de 1,96.

Le coefficient pour `dltotal(-1)` en comparaison avec `dlbrent` est quasiment proche de 1,96. Cela signifie que le filtre de différence première appliqué au logarithme du cours de Total, décalé d'une période, influence le comportement du cours du pétrole auquel on applique le logarithme, puis le filtre de différence première (c.f : Annexe: figure 37).

Ordre de décomposition de Cholesky

La première étape avant la représentation des réponses impulsionnelles à utiliser pour interprétation est la détermination de l'ordre de Cholesky. Il s'agit de classer les variables de la plus exogène à la moins exogène, c'est-à-dire de celle dont les chocs impactent plus toutes les autres à celle dont les chocs impactent moins les autres. (c.f: Annexe figure 40)

Test d'exogénéité

Hypothèses du test

H_0 : Exogénéité

H_1 : Non exogénéité

Règle de décision

- Si la probabilité associée à la variable considérée comme exogène est supérieure à 0,05, alors on accepte l'hypothèse nulle d'exogénéité.
- Si la probabilité associée à la variable considérée comme exogène est inférieure à 0,05, alors on rejette l'hypothèse nulle d'exogénéité.

Les résultats du test d'exogénéité sont les suivants :

Variable dépendante	Variable exclue	Prob
DLTOTAL	DLCAC40	0,8013
	DLBRENT	0,1132
	ALL	0,2286
DLCAC40	DLTOTAL	0,2721
	DLBRENT	0,4207
	ALL	0,47
DLBRENT	DLTOTAL	0,9565
	DLBRENT	0,4353
	ALL	0,6296

Table 14: Test d'exogénéité des variables

Variable dépendante : DLTOTAL

- **DLCAC40 exclu** : Prob. = 0.8013

La probabilité est très élevée, ce qui signifie qu'il n'y a pas de causalité de Granger de DLCAC40 vers DLTOTAL. Autrement dit, les valeurs passées de DLCAC40 n'aident pas à prédire DLTOTAL.

- **DLBRENT exclu** : Prob. = 0.1132
La probabilité est relativement basse, mais reste au-dessus du seuil de signification de 0.05. Cela suggère qu'il n'y a pas de causalité de Granger significative de DLBRENT vers DLTOTAL, bien que cette relation soit plus proche de la signification statistique par rapport à DLCAC40.
- **Toutes les variables exclues** : Prob. = 0.2286
La probabilité est élevée, indiquant qu'il n'y a pas de causalité de Granger significative des variables combinées (DLCAC40 et DLBRENT) vers DLTOTAL.

Variable dépendante : DLCAC40

- **DLTOTAL exclu** : Prob. = 0.2721
La probabilité est relativement élevée, ce qui signifie qu'il n'y a pas de causalité de Granger de DLTOTAL vers DLCAC40. Les valeurs passées de DLTOTAL n'aident pas à prédire DLCAC40.
- **DLBRENT exclu** : Prob. = 0.4207
La probabilité est également élevée, suggérant qu'il n'y a pas de causalité de Granger de DLBRENT vers DLCAC40. Les valeurs passées de DLBRENT n'aident pas à prédire DLCAC40.
- **Toutes les variables exclues** : Prob. = 0.4700
La probabilité est élevée, indiquant qu'il n'y a pas de causalité de Granger significative des variables combinées (DLTOTAL et DLBRENT) vers DLCAC40.

Variable dépendante : DLBRENT

- **DLTOTAL exclu** : Prob. = 0.9565
La probabilité est très élevée, ce qui signifie qu'il n'y a pas de causalité de Granger de DLTOTAL vers DLBRENT. Les valeurs passées de DLTOTAL n'aident pas à prédire DLBRENT.
- **DLCAC40 exclu** : Prob. = 0.4353
La probabilité est élevée, indiquant qu'il n'y a pas de causalité de Granger de DLCAC40 vers DLBRENT. Les valeurs passées de DLCAC40 n'aident pas à prédire DLBRENT.
- **Toutes les variables exclues** : Prob. = 0.6296
La probabilité est élevée, suggérant qu'il n'y a pas de causalité de Granger significative des variables combinées (DLTOTAL et DLCAC40) vers DLBRENT.

Synthèse des résultats

Les résultats des tests de causalité de Granger montrent qu'aucune des variables (DLTOTAL, DLCAC40, DLBRENT) n'a d'influence causale significative sur les autres. Les probabilités élevées suggèrent une indépendance relative entre ces variables dans le cadre des données analysées. Cela indique que les relations dynamiques entre ces variables ne sont pas suffisamment fortes pour prédire significativement les unes à partir des autres.

Fonction de Réponses Impulsionnelles

Représentées sous forme de graphiques, elles permettent d'appréhender l'effet sur une variable d'un choc (i_t) subi par une autre variable.




Figure 6: Fonctions de réponses impulsionnelles

Interprétation des fonctions de réponses impulsionnelles

Sur l'axe des abscisses des graphiques, on peut lire les retards et sur l'axe des ordonnées, l'intensité de la réaction. On remarque que globalement, les chocs s'amortissent à partir de la période $t + 3$. Autrement dit, tous les chocs datant d'une période supérieure à $t - 3$ n'ont aucun impact sur les variations des cours.

Sur la diagonale des graphiques, les réponses des variables à leurs propres innovations montrent des effets transitoires. Pour **DLTOTAL**, un choc interne entraîne une réaction positive significative, mais l'effet décroît rapidement et s'atténue autour de zéro après environ trois périodes. Ce comportement reflète une forte dépendance à ses propres chocs internes, mais avec un impact de courte durée. **DLCAC40** présente également une forte réaction initiale à ses propres innovations, suivie d'un retour rapide à zéro en trois périodes, caractéristique d'un marché financier autocorrélé où les chocs se dissipent rapidement. Enfin, **DLBRENT** réagit très fortement à ses propres chocs, avec une décroissance rapide et une stabilisation en trois périodes, comportement courant dans les marchés de matières premières où les ajustements des prix sont rapides.

Concernant les effets croisés, les interactions entre ces variables révèlent des relations asymétriques. Un choc sur **DLCAC40** a un effet légèrement positif et transitoire sur **DLTOTAL**, avec un point modéré après une période. Cela montre que les performances globales du marché boursier influencent modérément Total. Cependant, un choc sur **DLBRENT** a un impact significatif et positif sur **DLTOTAL**, indiquant une forte dépendance de Total aux variations des prix du pétrole brut, avec un ajustement rapide en trois périodes. À l'inverse, l'impact de **DLTOTAL** sur **DLCAC40** est négligeable, reflétant la faible représentation de Total dans le CAC40, un indice largement diversifié.

De même, un choc sur **DLBRENT** induit un effet transitoire faible et légèrement négatif sur **DLCAC40**, suggérant un lien indirect, probablement dû à l'impact des prix du pétrole sur les coûts énergétiques des entreprises.

En ce qui concerne **DLBRENT**, un choc provenant de **DLTOTAL** entraîne une réponse initiale positive mais faible, indiquant une répercussion modérée. Un choc sur **DLCAC40** engendre une réponse initialement positive de faible amplitude sur **DLBRENT**, traduisant une corrélation indirecte via les attentes macroéconomiques.

D'une manière générale, les résultats montrent une forte interdépendance entre Total et le Brent, cohérente avec la nature de l'industrie pétrolière, tandis que le CAC40 exerce une influence limitée sur ces deux variables, bien que des effets indirects puissent être observés. Tous les chocs analysés ont des effets transitoires, se dissipant généralement en trois périodes. Cela souligne la nécessité pour les investisseurs et décideurs de réagir rapidement aux chocs, car leurs impacts sont de courte durée.

Ces dynamiques mettent en évidence que Total est particulièrement sensible aux variations du Brent, tandis que l'influence du CAC40 demeure marginale dans ce contexte.

Décomposition de la variance

Cette étape a pour objectif de calculer, pour chacune des innovations (chocs), sa contribution à la variance de l'erreur. En d'autres termes, il s'agit de déterminer le pourcentage de la variance de l'erreur qui est expliqué par un choc subi par une variable du système.

On observe alors, à la suite de nos résultats que (c.f. Annexe figure 39):

La décomposition de la variance présentée dans les tableaux couvre dix périodes pour trois variables : **DLTOTAL**, **DLCAC40**, et **DLBRENT**. Une observation notable est que, à partir de la période 3, les proportions des contributions à la variance des erreurs de prévision deviennent quasiment constantes, permettant ainsi une généralisation des interprétations.

Pour **DLTOTAL**, la variance de l'erreur de prévision est principalement due à ses propres chocs, représentant environ **97.75%** de la variance totale. Les chocs provenant de **DLCAC40** contribuent très faiblement, avec seulement **0.06%**, tandis que les chocs de **DLBRENT** représentent environ **2.19%**. Cela indique que **DLTOTAL** est largement influencé par ses propres dynamiques internes, avec une influence mineure des autres variables.

En ce qui concerne **DLCAC40**, la variance de l'erreur de prévision est également dominée par ses propres chocs, qui représentent environ **60.89%**. Les chocs de **DLTOTAL** contribuent à hauteur de **38.59%**, montrant une influence modérée, alors que les chocs de **DLBRENT** ont une contribution négligeable de **0.51%**. **DLCAC40** est donc principalement autonome, avec une dépendance secondaire vis-à-vis de **DLTOTAL**.

Pour **DLBRENT**, la situation est quelque peu différente. La variance de l'erreur de prévision est due à environ **70.51%** à ses propres chocs, ce qui est significatif mais moins dominant comparé aux deux autres variables. Les chocs de **DLCAC40** contribuent à hauteur de **5.26%**, et ceux de **DLTOTAL** représentent environ **23.47%**. Cela montre que **DLBRENT** est plus sensible aux influences externes, notamment de **DLTOTAL**, comparé à **DLTOTAL** et **DLCAC40**.

En résumé, **DLTOTAL** et **DLCAC40** sont principalement influencés par leurs propres chocs, avec des contributions mineures des autres variables. En revanche, **DLBRENT**, bien qu'influencé majoritairement par ses propres chocs, montre une sensibilité plus élevée aux chocs externes, en particulier ceux de **DLTOTAL** (annexe 8 à 10).

5.4 Causalité au sens de Granger

Cette étape met en évidence les relations causales entre les variables économiques, permettant ainsi une meilleure compréhension des impacts de l'une sur les autres variables. Deux auteurs proposent des méthodes pour étudier la causalité entre variables : Granger et Sims.

Pour Granger, la variable Y_{2t} est la cause de la variable Y_{1t} si la prédictibilité de $Y_1(t)$ est améliorée lorsque l'information relative à $Y_2(t)$ est incorporée dans l'analyse. La causalité est étudiée entre les variables deux à deux.

Hypothèses du test

- H_0 : Y_2 n'est pas la cause de Y_1
- H_1 : Y_2 est la cause de Y_1

Statistique du test

$$F = \frac{(SCR_R - SCR_U)}{SCR_U} \times \frac{1}{n - k - 1} \sim F(DDL(SCR_R - SCR_U), DDL(SCR_U / (n - k - 1)))$$

avec SCR_U : SCR non contrainte de Y_1 , SCR_R : SCR de l'équation entre Y_1 et $Y_1(t - 1)$, k : le nombre de variables explicatives, et n : le nombre d'observations.

Règle de décision

- Si la statistique de test F est inférieure à la valeur du quantile pour un niveau de test à 5% de la table de Fisher, alors l'hypothèse nulle Y_2 n'est pas la cause de Y_1 est acceptée.
- Si la statistique de test F est supérieure à la valeur du quantile pour un niveau de test à 5% de la table de Fisher, alors l'hypothèse nulle Y_2 n'est pas la cause de Y_1 est rejetée.

Null Hypothesis	F-Statistic	Prob.
DLCAC40 does not Granger Cause DLTOTAL	0.43761	0.5095
DLTOTAL does not Granger Cause DLCAC40	0.86409	0.3544
DLBRENT does not Granger Cause DLTOTAL	2.91010	0.0905
DLTOTAL does not Granger Cause DLBRENT	0.31772	0.5740
DLBRENT does not Granger Cause DLCAC40	0.30336	0.5828
DLCAC40 does not Granger Cause DLBRENT	0.92989	0.3368

Table 15: Causalité au Sens de Granger (c.f : Annexe figure 41)

Interprétation des résultats

On remarque que toutes les probabilités obtenues à partir des tests de causalité de Granger sont strictement supérieures à 5%. Cela signifie que nous acceptons l'hypothèse nulle selon laquelle il n'y a pas de relation de causalité entre les variables testées.

Pour chaque paire de variables dans le tableau ci-dessus, les résultats des tests indiquent qu'aucune des variables passées n'a un effet significatif sur les autres.

- Les valeurs passées de **DLCAC40** n'aident pas à prédire **DLTOTAL**, et de même, les valeurs passées de **DLTOTAL** n'aident pas à prédire **DLCAC40**.
- Les valeurs passées de **DLBRENT** n'aident pas à prédire **DLTOTAL**, et de même, les valeurs passées de **DLTOTAL** n'aident pas à prédire **DLBRENT**.
- Les valeurs passées de **DLBRENT** n'aident pas à prédire **DLCAC40**.

Cette absence de causalité est également observée pour les autres paires de variables, y compris **DLBRENT**, et montre que chaque variable semble évoluer de manière indépendante des autres.

Ces résultats viennent corroborer les conclusions tirées de la décomposition de la variance pour chaque variable. En effet, la décomposition de la variance avait montré que la majorité de la variance de chaque variable était expliquée par ses propres chocs, avec des contributions assez faibles des autres variables. Les tests de causalité de Granger confirment cette indépendance en montrant qu'il n'y a pas de relations de causalité significatives entre les variables.

5.5 Causalité au sens de Sims

Le test de causalité au sens de Sims est une méthode développée par Christopher Sims pour analyser la relation causale entre plusieurs séries temporelles dans un cadre de modèle vectoriel autorégressif. Le test de Sims permet de tester la causalité bidirectionnelle, c'est-à-dire la possibilité que chaque variable dans un système de variables puisse influencer les autres variables simultanément.

L'objectif est de tester les effets de chaque variable (en tenant compte des autres variables du modèle) pour savoir si elle contient de l'information utile pour prédire l'évolution des autres variables dans le futur.

Hypothèses du test

H_0 : les coefficients de retards de X dans l'équation de Y sont égaux à 0

H_1 : les coefficients de retards de X dans l'équation de Y sont non nuls

Statistique du test

$$F = \frac{(RSS_{\text{restreint}} - RSS_{\text{non-restreint}})/K}{RSS_{\text{non-restreint}}/(N - K - 1)}$$

Où :

- $RSS_{\text{restreint}}$ est la somme des carrés des résidus du modèle avec les restrictions (c'est-à-dire, avec les coefficients de retard de $X(t)$ fixés à zéro),
- $RSS_{\text{non-restreint}}$ est la somme des carrés des résidus du modèle sans les restrictions,
- K est le nombre de restrictions (le nombre de coefficients de retard de $X(t)$),
- N est le nombre d'observations.

Règle de décision

- Si la p-value est inférieure à la valeur du quantile pour un niveau de test à 5% de la table de Fisher, alors on rejette l'hypothèse nulle et on conclut que la variable X Granger cause Y ou que Y Granger cause X , selon la direction du test.
- Si la p-value est supérieure à la valeur du quantile pour un niveau de test à 5% de la table de Fisher, alors on accepte l'hypothèse nulle et on conclut qu'il n'y a pas de causalité significative entre X et Y dans le cadre du modèle VAR.

	DLTOTAL	DLCAC40	DLBRENT
DLTOTAL	0.004364	0.001919	0.003742
DLCAC40	0.001919	0.002217	0.002651
DLBRENT	0.003742	0.002651	0.014002

La matrice de covariance des résidus d'un modèle à vecteur autorégressif fournit des informations sur les relations entre les variables étudiées. La matrice de covariance des résidus montre comment les résidus de chaque équation du modèle VAR sont corrélés entre eux, ce qui permet d'identifier les relations instantanées entre les variables (c.f : Annexe figure 43).

Si la covariance entre les résidus de deux variables est relativement élevée, cela indique une forte relation entre ces variables. On peut alors conclure qu'il y a une causalité instantanée significative entre ces variables. Si la covariance entre les résidus de deux variables est faible, cela indique une relation faible entre ces variables. On peut alors conclure qu'il n'y a pas de causalité instantanée significative entre ces variables.

- **DLTOTAL et DLCAC40 :**

La covariance est de 0.001919, très faible, indiquant une relation limitée entre DLTOTAL et DLCAC40. Il n'y a donc pas de causalité instantanée significative entre ces deux variables.

- **DLTOTAL et DLBRENT :**

La covariance est de 0.003742, légèrement plus élevée que celle entre DLTOTAL et DLCAC40, mais reste modérée. Cela indique une relation relativement significative entre DLTOTAL et DLBRENT. On peut conclure qu'il y a une causalité instantanée modérée entre ces deux variables.

- **DLCAC40 et DLBRENT :**

La covariance est de 0.002651, modérée, indiquant une relation limitée entre DLCAC40 et DLBRENT. Il n'y a donc pas de causalité instantanée significative entre ces deux variables.

En appliquant la règle de décision basée sur les covariances des résidus, nous constatons que les relations entre les variables DLTOTAL, DLCAC40 et DLBRENT sont généralement modérées mais non négligeables. Cela signifie que les chocs instantanés affectant une variable ont un impact limité sur les autres variables. Ces résultats suggèrent que, dans le cadre du modèle VAR estimé, les variables évoluent principalement de manière indépendante les unes des autres en termes de chocs instantanés.

Ces résultats suggèrent que, dans le cadre du modèle VAR estimé, les variables évoluent de manière relativement indépendante les unes des autres en termes de chocs instantanés.

5.6 Modèle à Correction d'Erreurs Vectoriel (VECM)

Le test de cointégration de Johansen

Ce test procède par la détermination du rang d'une matrice qui correspond au nombre de vecteurs cointégrants. Il utilise deux statistiques que sont la statistique de la trace et la statistique du maximum de la valeur propre. Ces tests sont faits de manière séquentielle.

Hypothèses du test

H_0 : Rang de la matrice = 0 ou $\geq k \rightarrow$ pas de cointégration

H_1 : Rang de la matrice $\in [1; k - 1] \rightarrow$ cointégration

Règle de décision

- Si la statistique de la trace est inférieure à la valeur critique, le processus séquentiel est interrompu et le rang associé à cette statistique de la trace spécifique est sélectionné.
- Si la statistique du maximum de la valeur propre est inférieure à la valeur critique, le processus séquentiel est alors arrêté, et le rang correspondant à cette statistique du maximum de la valeur propre est choisi.

Test	Hypothèse	Eigenvalue	Statistic	Critical Value	Prob
Trace	None *	0.501784	192.1656	29.79707	0.0000
Trace	At most 1 *	0.367828	103.6821	15.49471	0.0000
Trace	At most 2 *	0.300788	45.44068	3.841465	0.0000

Table 16: Test de cointégration de Johansen (Trace)

Test					
Max-Eigenvalue	None *	0.501784	97.48967	21.13162	0.00000
Max-Eigenvalue	At most 1 *	0.367828	71.30604	14.26460	0.00000
Max-Eigenvalue	At most 2 *	0.300788	45.44068	3.841465	0.00000

Le test de cointégration de Johansen présenté indique qu'il y a 3 relations de cointégration entre les variables étudiées (DLTOTAL, DLCAC40, et DLBRENT) à un seuil de 5 %. Cela signifie que l'hypothèse nulle est rejetée dans chaque cas.

Le modèle VECM n'est pas adapté et ne peut pas être estimé dans notre cas car le test de Johansen indique la présence de 3 relations de cointégration, ce qui correspond exactement au nombre de variables de notre système ($n = 3$). Cela signifie que les variables sont totalement cointégrées, formant un système parfaitement lié à long terme, où les déviations par rapport aux équilibres sont entièrement expliquées par les relations de cointégration. Or, un VECM est conçu pour modéliser des systèmes partiellement cointégrés, c'est-à-dire lorsqu'il y a moins de relations de cointégration ($r < n$), permettant ainsi de capturer à la fois les dynamiques de court terme et les ajustements vers les équilibres de long terme.

Lorsque l'on travaille avec des séries différenciées (ΔY_t), le modèle le plus adapté est le VAR classique. La différenciation première permet de transformer des séries non stationnaires en séries stationnaires, ce qui rend les données compatibles avec les hypothèses du VAR classique. Ce modèle est conçu pour capturer les dynamiques à court terme entre les variables, sans prendre en compte les relations de long terme ou les tendances potentielles présentes dans les séries initiales. Le VAR classique se concentre uniquement sur les variations immédiates entre les variables différenciées ce qui permet d'analyser des interactions de court terme ou les réponses aux chocs entre ces séries.

Cependant, lorsque l'on travaille avec des séries différenciées, on perd les informations liées aux relations de cointégration ou d'équilibre à long terme entre les variables, car ces relations sont éliminées par le processus de différenciation. Par conséquent, bien que le VAR classique soit efficace pour modéliser les interactions à court terme, il ne permet pas d'explorer les ajustements vers un équilibre ou les dynamiques de long terme.

5.7 Conclusion

L'objectif de ce chapitre 2 était d'analyser les résultats combinés des fonctions de réponses impulsionnelles, de la décomposition de la variance et des tests de causalité de Granger et de Sims. Ces outils offrent une vision approfondie des dynamiques d'interaction entre les variables DLTOTAL, DLBRENT et DLCAC.

Les fonctions de réponses impulsionnelles révèlent des effets transitoires entre les variables. Le cours de Total montre une sensibilité forte et immédiate aux innovations provenant du Brent, confirmant une dépendance significative au marché pétrolier. En revanche, les réponses de Total aux innovations du CAC40 sont faibles et temporaires, indiquant une influence peu significative des marchés financiers globaux sur cette action spécifique. Les interactions entre le Brent et le CAC40 sont également limitées, bien que des corrélations indirectes via des attentes macroéconomiques soient visibles.

La décomposition de la variance complète cette analyse en quantifiant l'importance relative de chaque variable dans la variation future des autres. Les résultats montrent que la variance de DLTOTAL est majoritairement expliquée par DLBRENT, ce qui confirme une relation structurelle entre Total et le marché pétrolier. À l'inverse, le CAC40 joue un rôle mineur dans l'explication des fluctuations des deux autres variables, soulignant une faible interdépendance directe.

Les tests de causalité de Granger confirment que le Brent exerce une causalité significative sur Total, ce qui est cohérent avec les résultats des autres analyses. Le CAC40 n'a pas de pouvoir prédictif notable sur le Brent ou Total, corroborant l'idée que ses effets sont indirects ou marginaux. Les tests de Sims, quant à eux, mettent en lumière l'existence de rétroactions faibles mais présentes, notamment entre Total et le Brent, suggérant une interdépendance bidirectionnelle limitée.

Le test de Johansen a révélé l'existence de trois relations de cointégration entre les variables DLTOTAL, DLBRENT et DLCAC40. Cela démontre qu'il existe des relations structurelles de long terme entre ces variables. Cependant, en différenciant les séries, ces relations de cointégration ne peuvent plus être exploitées directement, car la différenciation élimine les informations sur les équilibres de long terme. Ainsi, bien qu'un modèle VAR classique sur des séries différenciées soit capable de modéliser efficacement les interactions de court terme, il ne permet pas d'examiner les ajustements vers les relations d'équilibre de long terme.

En synthèse, cette étude met en évidence le rôle central du Brent comme moteur principal des fluctuations de Total, reflétant la dépendance de l'industrie pétrolière aux prix des matières premières. Le CAC40, bien qu'influencé par des dynamiques macroéconomiques, n'exerce qu'un impact limité sur Total et le Brent. Les effets transitoires observés dans les réponses impulsionnelles, ainsi que les résultats des autres tests, indiquent que les chocs se dissipent rapidement, soulignant l'importance d'une réactivité accrue pour les investisseurs face aux variations de ces marchés.

6 Chapitre 3: Étude sur les Déterminants de Souscription aux Dépôts à Termes

6.1 Introduction

L'utilisation de techniques avancées d'analyse de données dans le secteur bancaire et d'assurance a considérablement évolué au cours des dernières années, en particulier dans le cadre des campagnes de marketing direct. Ces campagnes ont pour objectif de promouvoir des produits bancaires spécifiques auprès des clients en fonction de leurs caractéristiques socio-économiques et de leur comportement passé, soit par voie directe ou indirecte via le téléphone, les réseaux sociaux ou Internet.

Ce projet se concentre sur l'analyse d'un jeu de données provenant d'une campagne de marketing direct réalisée par une institution bancaire portugaise. Les données générées par cette campagne, qui a eu lieu entre mai 2008 et novembre 2010, reposent sur des appels téléphoniques visant à proposer un produit bancaire aux clients. Pour chaque client, plusieurs contacts ont été nécessaires avant de déterminer si ce dernier allait souscrire au produit, ce qui a permis de collecter une série de données détaillées. Le jeu de données contient des informations sur les caractéristiques démographiques des clients (comme l'âge, le statut marital et l'éducation), ainsi que sur leurs interactions avec la banque, notamment la durée des appels et le nombre de contacts effectués.

Dans ce contexte, la problématique principale est la suivante : **Comment utiliser les données issues des campagnes de marketing direct pour prédire efficacement la probabilité qu'un client souscrive à un dépôt à terme, en s'appuyant sur des modèles économétriques tels que Probit et Logit, et en tenant compte des caractéristiques socio-économiques des clients et des interactions bancaires ?**

Pour répondre à cette question, nous utilisons un échantillon aléatoire de 4 521 observations tirées de la base de données initiale, qui contient environ 45 211 enregistrements (soit 10 %). Les 16 variables explicatives couvrent un large éventail de facteurs susceptibles d'affecter le comportement des clients, allant des données personnelles, telles que l'âge et l'emploi occupé, à des caractéristiques liées aux campagnes de marketing, comme la durée des appels et le nombre de contacts. En appliquant des modèles économétriques adaptés, nous cherchons à déterminer les principaux déterminants de la souscription et à prédire efficacement les comportements des clients.

6.2 Données et Analyse Descriptives

Données

Dans ce projet, nous utilisons un jeu de données issu des campagnes de marketing direct d'une institution bancaire portugaise. Ces données couvrent la période de mai 2008 à novembre 2010 et consistent en des appels téléphoniques réalisés pour proposer un produit bancaire spécifique : un dépôt à terme. Le jeu de données contient deux versions : une version complète avec 45 211 observations et une version réduite avec 4 521 observations, destinée aux algorithmes nécessitant moins de ressources computationnelles.

Le jeu de données comprend 17 variables, dont 16 explicatives et une variable cible qui indique si le client a souscrit au produit proposé ou non. Ces variables incluent des informations démographiques, socio-économiques, ainsi que des détails sur les interactions bancaires et les résultats des campagnes précédentes. L'objectif est de prédire la probabilité qu'un client souscrive à un dépôt à terme en fonction de ces caractéristiques.

Variable	Type	Description
age	Numérique	Âge du client
job	Catégorique	Type d'emploi (admin., technician, services, etc.)
marital	Catégorique	État matrimonial (married, single, divorced)
education	Catégorique	Niveau d'éducation (primary, secondary, tertiary, unknown)
default	Binaire	Le client a-t-il un crédit en défaut ? (yes, no)
balance	Numérique	Solde annuel moyen (en euros)
housing	Binaire	Le client a-t-il un crédit immobilier ? (yes, no)
loan	Binaire	Le client a-t-il un prêt personnel ? (yes, no)
contact	Catégorique	Type de communication utilisé (telephone, cellular)
day	Numérique	Jour du dernier contact dans le mois
month	Catégorique	Mois du dernier contact (jan, feb, mar)
duration	Numérique	Durée du dernier contact (en secondes)
campaign	Numérique	Nombre total de contacts effectués pour cette campagne
pdays	Numérique	Nombre de jours depuis le dernier contact dans une campagne précédente (-1 si aucun contact)
previous	Numérique	Nombre de contacts effectués avant cette campagne
poutcome	Catégorique	Résultat de la campagne marketing précédente (success, failure, unknown)
y	Binaire	Le client a-t-il souscrit au dépôt à terme ? (yes, no)

Table 17: Description des variables du jeu de données

Analyse Graphiques et Statistiques

Le graphique illustre la distribution de la variable cible 'y', qui représente la souscription à un dépôt à terme parmi les clients. Sur un total de clients évalués, 88.5% n'ont pas souscrit à un dépôt à terme, ce qui correspond à environ 4000 clients, tandis que seulement 11.5% ont choisi de souscrire, soit environ 500 clients. Cette distribution montre une prédominance claire des non-souscriptions, indiquant que la majorité des clients dans l'échantillon n'ont pas opté pour ce produit financier.




Figure 7

Variables Numériques

L'analyse statistique descriptive de ces variables (annexe) utiliser pour prédire la souscription à un dépôt à terme dans le cadre de campagnes de marketing direct d'une institution bancaire portugaise révèle plusieurs insights intéressants:

Age: L'âge moyen des clients est de 41,17 ans, avec une distribution qui montre une plage allant de 19 à 87 ans. La médiane à 39 ans suggère que la population est légèrement plus jeune que la moyenne, indiquant une distribution légèrement asymétrique vers les âges plus jeunes.

Balance: La balance moyenne annuelle des comptes est de 1422,65 euros, avec une grande variance (std = 3009,63) due à des valeurs extrêmes allant de -3313 à 71188 euros. Cela montre une grande diversité dans les situations financières des clients, avec certains ayant des soldes négatifs et d'autres des soldes très élevés. La médiane à 444 euros suggère que la majorité des clients ont des soldes relativement modestes.

Day: Le jour moyen du dernier contact est le 15,91, avec des valeurs allant de 1 à 31, ce qui couvre toute la gamme des jours du mois. La distribution semble assez uniforme, avec la médiane au 16ème jour.

Duration: La durée moyenne des appels de contact est de 263,96 secondes (environ 4,4 minutes), avec une dispersion assez large ($\text{std} = 259,86$). Cela indique que la durée des appels varie considérablement, allant de 4 à 3025 secondes, ce qui pourrait être un indicateur fort de l'intérêt ou de l'engagement du client.

Campaign: En moyenne, il y a eu 2,79 contacts par client durant la campagne actuelle, avec un maximum de 50 contacts. Cela montre que certaines campagnes nécessitent de multiples tentatives pour convaincre un client. La médiane à 2 indique que la plupart des clients ont été contactés deux fois ou moins.

Pdays: La valeur moyenne de 39,76 jours montre que, pour les clients précédemment contactés, il s'est écoulé en moyenne environ un mois et une semaine depuis le dernier contact. La valeur -1, qui représente 75% des cas (quartile 25 à 75), signifie que la majorité des clients n'ont pas été contactés dans des campagnes antérieures.

Previous: Avec une moyenne de 0,54, cela suggère que la plupart des clients n'ont pas été contactés avant cette campagne, ce qui est confirmé par le fait que 75% des clients ont une valeur de 0 pour cette variable.

Ces résultats indiquent une population client diverse en termes d'âge et de situation financière, avec des stratégies de contact variées en fonction de la réactivité des clients. La durée de l'appel semble être une variable potentiellement significative pour prédire la souscription, car elle pourrait refléter l'intérêt du client. De plus, le fait que la majorité des clients n'ont pas été contactés dans des campagnes précédentes pourrait suggérer que chaque campagne doit être traitée comme une nouvelle opportunité de convaincre, plutôt que de s'appuyer sur des interactions passées. Pour les modèles prédictifs comme le modèle Probit, ces variables fournissent des insights précieux sur les caractéristiques des clients et les dynamiques des campagnes de marketing qui pourraient influencer la décision de souscription à un dépôt à terme.

Variables Qualitatives

Les variables catégorielles du jeu de données incluent plusieurs informations qualitatives relatives aux clients, à leur situation personnelle et aux interactions avec la campagne marketing. La variable `job` présente 12 types de professions, parmi lesquels "management" est le plus fréquent. Concernant le `marital`, il y a trois statuts : "married" (marié), "divorced" (divorcé) et "single" (célibataire), avec une majorité de clients mariés. En termes d'éducation (`education`), les catégories "secondary" (secondaire), "tertiary" (tertiaire), et "primary" (primaire) sont représentées, et la plus grande part des clients a un niveau d'éducation secondaire. La variable `default` indique si un client a des crédits en défaut, et la grande majorité des clients ont répondu "no", signifiant l'absence de défaut de paiement.

La présence d'un `housing loan` (prêt immobilier) est courante, avec plus de la moitié des clients ayant ce type de prêt, tandis que les prêts personnels (`loan`) sont moins fréquents. Le `contact` utilisé pour joindre les clients est majoritairement le téléphone cellulaire, et le `month` indique le mois de dernier contact, où le mois de mai ressort comme le plus fréquent.

Enfin, la variable `poutcome` montre les résultats de la campagne précédente, avec "unknown" (inconnu) étant la catégorie dominante, ce qui suggère que de nombreux clients n'avaient pas d'historique de contact avant cette campagne. L'analyse de ces variables catégorielles permet d'identifier les profils de clients les plus susceptibles de répondre à la campagne marketing et d'orienter les prédictions sur la souscription au dépôt à terme.

6.3 Analyse de la Corrélation entre les variables

6.3.1 Variables Numériques

Présentation de la méthode de Kendall

Pour analyser la corrélation entre nos variables numériques, nous avons privilégié la méthode de Kendall au lieu de Pearson, qui évalue uniquement la relation linéaire. Aussi appelée τ de Kendall, elle est une mesure non paramétrique de l'association entre deux variables ordinales. Elle évalue la force et la direction d'une relation monotone entre deux variables. Cette méthode repose sur le comptage des paires concordantes et discordantes dans les données.

La formule de τ de Kendall est donnée par :

$$\tau = \frac{C - D}{\frac{1}{2}n(n - 1)}$$

où :

- C est le nombre de paires concordantes,
- D est le nombre de paires discordantes,
- n est le nombre total d'observations.

Un τ proche de 1 indique une forte association positive, tandis qu'un τ proche de -1 indique une forte association négative. Un τ proche de 0 indique une absence d'association.

Résultats de la corrélation de Kendall entre les variables

	age	education	balance	day	duration	campaign	pdays	previous	poutcome
age	1.000000	-0.147400	0.051505	-0.017031	-0.024849	0.018897	-0.000840	0.000526	0.005218
education	-0.147400	1.000000	0.043071	0.012698	-0.000314	0.016841	0.024146	0.033639	0.030748
balance	0.051505	0.043071	1.000000	-0.007962	0.035923	-0.024134	0.048403	0.054271	0.056869
day	-0.017031	0.012698	-0.007962	1.000000	-0.034289	0.108478	-0.066586	-0.062743	-0.063912
duration	-0.024849	-0.000314	0.035923	-0.034289	1.000000	-0.066681	0.028551	0.031875	0.035758
campaign	0.018897	0.016841	-0.024134	0.108478	-0.066681	1.000000	-0.119233	-0.119460	-0.129985
pdays	-0.000840	0.024146	0.048403	-0.066586	0.028551	-0.119233	1.000000	0.905505	0.914623
previous	0.000526	0.033639	0.054271	-0.062743	0.031875	-0.119460	0.905505	1.000000	0.928425
poutcome	0.005218	0.030748	0.056869	-0.063912	0.035758	-0.129985	0.914623	0.928425	1.000000

Table 18: Matrice des corrélations basée sur les résultats obtenus.

L'analyse de cette matrice de corrélation révèle plusieurs observations importantes :

- La plupart des corrélations entre les variables sont faibles à modérées, ce qui suggère une multicolinéarité limitée pour l'ensemble des variables. Cependant, certaines paires de variables montrent des corrélations plus marquées qu'il est important de considérer.
- Une corrélation notable est celle entre *age* et *education*, avec un coefficient de -0.1474 , indiquant une relation négative modérée où les personnes plus âgées pourraient avoir un niveau d'éducation plus bas dans ce jeu de données spécifique.
- Les variables *pdays*, *previous* et *poutcome* présentent des corrélations très élevées (supérieures à 0.9), ce qui signale une forte multicolinéarité entre elles. Ces variables sont toutes liées à l'historique de contact avec le client, suggérant une redondance d'information.
- La variable *day* affiche des corrélations très faibles avec la plupart des autres variables, indiquant qu'elle pourrait apporter une information unique sans introduire de multicolinéarité significative.
- La *duration* de l'appel montre des corrélations faibles à modérées, ce qui pourrait être significatif dans la prédiction de la souscription à un dépôt à terme.

Pour les modèles de régression Probit ou Logit où l'objectif est de prédire la souscription à un dépôt à terme (y), voici nos recommandations pour la sélection des variables :

- **Inclure** dans les modèles : *age*, *education*, *balance*, *duration* et *campaign*. Ces variables semblent fournir une information pertinente sans introduire une multicolinéarité sévère.
- **Sélectionner une seule variable** parmi *pdays*, *previous* et *poutcome*. Étant donné leur forte corrélation mutuelle, nous avons choisi *previous* pour éviter la redondance.
- **Suppression de *day***, car elle présente des corrélations très faibles avec les autres variables.

En conclusion, l'inclusion sélective des variables dans les modèles de régression devrait viser à maximiser l'information prédictive tout en minimisant les effets de la multicolinéarité pour des résultats plus fiables et interprétables.

6.3.2 Variables Categorielles

Dans cette analyse, nous avons utilisé la méthode du χ^2 pour mesurer l'association et la corrélation entre différentes variables qualitatives. Ce test statistique est particulièrement adapté pour évaluer si une relation significative existe entre deux variables catégoriques.

elle repose sur une comparaison entre les fréquences observées dans un tableau de contingence et les fréquences attendues sous l'hypothèse d'indépendance entre les variables. L'hypothèse nulle (H_0) stipule qu'il n'existe pas de relation entre les variables, tandis que l'hypothèse alternative (H_1) postule une dépendance significative entre elles. La formule permettant de calculer la statistique du χ^2 est donnée par :

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

où :

- O_{ij} est la fréquence observée dans la cellule i, j ,
- E_{ij} est la fréquence attendue dans la cellule i, j , calculée sous l'hypothèse d'indépendance.

Le test permet d'obtenir une p -valeur associée, qui indique si les relations observées sont statistiquement significatives. Une p -valeur inférieure à 0.05 rejette l'hypothèse nulle et confirme une association significative.

	job	marital	default	housing	loan	contact	month	y
job	NaN	1.372525e-65	0.593637	1.069462e-74	1.988689e-06	6.845694e-36	1.128239e-94	1.901391e-10
marital	1.372525e-65	NaN	0.002083	1.604635e-02	4.338737e-03	6.132633e-06	2.335952e-04	7.373535e-05
default	5.936374e-01	2.083335e-03	NaN	7.293900e-01	3.441355e-05	2.819470e-01	9.627249e-02	1.000000e+00
housing	1.069462e-74	1.604635e-02	0.729390	NaN	2.305655e-01	8.870387e-48	5.034022e-226	2.714700e-12
loan	1.988689e-06	4.338737e-03	0.000034	2.305655e-01	NaN	8.511144e-01	8.863068e-28	2.914829e-06
contact	6.845694e-36	6.132633e-06	0.281947	8.870387e-48	8.511144e-01	NaN	0.000000e+00	8.304301e-20
month	1.128239e-94	2.335952e-04	0.096272	5.034022e-226	8.863068e-28	0.000000e+00	NaN	2.195355e-47
y	1.901391e-10	7.373535e-05	1.000000	2.714700e-12	2.914829e-06	8.304301e-20	2.195355e-47	NaN

Figure 8

Dans cette analyse, nous avons utilisé le test du Khi-deux pour examiner l'association entre différentes variables catégorielles et la variable cible y (Souscription aux Dépôts à Terme). Les résultats du test ont révélé plusieurs variables présentant une association statistiquement significative avec y , avec des p -valeurs inférieures à 0.05, suggérant une corrélation forte. Parmi ces variables, on retrouve : **job** (p -value = 1.901391e-10), **marital** (p -value = 7.373535e-05), **housing** (p -value = 2.714700e-12), **loan** (p -value = 2.914829e-06), **contact** (p -value = 8.304301e-20), et **month** (p -value = 2.195355e-47).

Cependant, afin de réduire le risque de multicollinéarité, il est crucial d'éviter les variables qui sont fortement corrélées entre elles. En analysant les résultats, nous avons observé que certaines variables, telles que **job** et **housing**, sont particulièrement significativement corrélées entre elles, ce qui suggère un certain degré de redondance. De plus, **loan** et **contact** présentent une corrélation faible mais significative.

En tenant compte de ces éléments, une combinaison optimale de variables pour un modèle prédictif, tout en minimisant la multicollinéarité, pourrait inclure : **housing**, **loan**, **contact** et **month**. Ces variables sont non seulement significativement associées à la variable cible y , mais elles ne présentent pas de corrélation excessive entre elles, ce qui réduit le risque de multicollinéarité et améliore la performance du modèle.

6.4 Modélisation

Dans cette section, nous testons deux modèles, Logit et Probit, afin de déterminer lequel est le plus adapté à nos données. Après avoir analysé les résultats de corrélation entre nos variables numériques pour identifier toute forme de multicollinéarité susceptible d'altérer nos résultats, nous avons conclu qu'il est possible d'inclure toutes les variables, mais nous avons finalement retenu les suivantes : housing, loan, contact, age, education, balance, duration, campaign et previous.

6.4.1 Régression modèle Probit

Le modèle probit, quant à lui, utilise la fonction de distribution cumulée (FDC) d'une loi normale standard pour estimer la probabilité que $y = 1$. La probabilité conditionnelle s'exprime ainsi :

$$P(y = 1|X) = \Phi(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)$$

où : - Φ représente la fonction de répartition de la loi normale standard ; - Les variables explicatives et coefficients sont similaires à ceux du modèle logit.

Le modèle probit est particulièrement utile lorsque les données présentent une distribution cumulative proche de la loi normale.

Résultats

Dans cette analyse, nous avons appliqué un modèle Probit pour évaluer les facteurs influençant la probabilité qu'un client souscrive un dépôt à terme. Le modèle Probit est un modèle de régression adapté aux variables dépendantes binaires, dans notre cas la variable y , codée comme suit :

- $y = 1$: le client a souscrit un dépôt à terme,
- $y = 0$: le client n'a pas souscrit de dépôt à terme.

Les coefficients estimés du modèle Probit sont résumés dans le tableau ci-dessous :

Variable	Coefficient	Significativité (p-value)
Intercept (C)	-2.536	$p < 0.01$
Housing (Prêt immobilier)	-0.342	$p < 0.01$
Loan (Prêt personnel)	-0.454	$p < 0.01$
Contact: Cellular	0.639	$p < 0.01$
Contact: Telephone	0.651	$p < 0.01$
Âge (Age)	0.004	$p > 0.05$
Niveau d'éducation (Education)	0.116	$p < 0.01$
Solde moyen annuel (Balance)	5.64×10^{-6}	$p > 0.1$
Durée du contact (Duration)	0.002	$p < 0.01$
Nombre de contacts (Campaign)	-0.057	$p < 0.05$
Contacts précédents (Previous)	0.070	$p < 0.01$

Table 19: Coefficients estimés du modèle Probit.

- **Intercept** : La constante du modèle indique que, lorsque toutes les variables explicatives sont nulles, la probabilité de souscription est très faible.
- **Housing (Prêt immobilier)** : Les clients ayant un prêt immobilier ont une probabilité plus faible de souscrire un dépôt à terme.

- **Loan (Prêt personnel)** : De même, les clients avec un prêt personnel sont moins susceptibles de souscrire un dépôt.
- **Contact (Cellular et Telephone)** : Les contacts via téléphone portable ou fixe augmentent significativement la probabilité de souscription par rapport à la catégorie de référence.
- **Âge (Age)** : L'âge n'a pas d'effet statistiquement significatif sur la probabilité de souscription.
- **Éducation (Education)** : Un niveau d'éducation plus élevé est associé à une probabilité accrue de souscription.
- **Solde moyen annuel (Balance)** : n'a pas d'effet statistiquement significatif.
- **Durée du contact (Duration)** : Plus la durée du contact est longue, plus la probabilité de souscription augmente.
- **Nombre de contacts (Campaign)** : Un nombre élevé de contacts dans la campagne actuelle est associé à une probabilité réduite de souscription.
- **Contacts précédents (Previous)** : Un historique de contacts plus élevé dans les campagnes précédentes augmente légèrement la probabilité de souscription.

Qualité du modèle

- **McFadden R-squared** : Le pseudo- R^2 du modèle est de 0.246, indiquant que 24.6% de la variance observée est expliquée par les variables incluses.
- **Statistique du test de vraisemblance (LR Statistic)** : Avec une valeur de 795.29 ($p < 0.01$), le modèle est globalement significatif.

Cette analyse met en évidence les principaux facteurs influençant la souscription à un dépôt à terme. Les variables liées aux contacts (**contact**), au niveau d'éducation (**education**) et à la durée des interactions (**duration**) jouent un rôle clé dans la probabilité de souscription, tandis que des variables comme l'âge n'ont pas d'effet significatif. Ces résultats peuvent guider les stratégies de ciblage pour les campagnes futures.

6.4.2 Regression du Modèle Logit

Le modèle logit repose sur la fonction logistique pour modéliser la probabilité que l'événement $y = 1$ (souscription à un dépôt à terme) se produise. La fonction de probabilité conditionnelle est définie comme suit :

$$P(y = 1|X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}$$

où : - $X_1, \dots, X_k$ représentent les variables explicatives ; - β_0 et $\beta_1, \dots, \beta_k$ sont les coefficients à estimer.

L'objectif est de maximiser la vraisemblance des observations, en ajustant les coefficients β de manière à ce que le modèle prévoie correctement les probabilités observées.

Résultats

Variable	Coefficient	Significativité (p-value)
Intercept (C)	-4.670	$p < 0.01$
Housing (Prêt immobilier)	-0.671	$p < 0.01$
Loan (Prêt personnel)	-0.892	$p < 0.01$
Contact: Cellular	1.291	$p < 0.01$
Contact: Telephone	1.289	$p < 0.01$
Âge (Age)	0.008	$p > 0.05$
Niveau d'éducation (Education)	0.220	$p < 0.01$
Solde moyen annuel (Balance)	7.27×10^{-6}	$p > 0.1$
Durée du contact (Duration)	0.003	$p < 0.01$
Nombre de contacts (Campaign)	-0.103	$p < 0.05$
Contacts précédents (Previous)	0.124	$p < 0.01$

Table 20: Coefficients estimés du modèle Logit.

Les résultats du modèle Logit montrent que plusieurs facteurs influencent la probabilité de souscription à un dépôt à terme. Comme pour le modèle Probit, les contacts via téléphone portable ou fixe, le niveau d'éducation et la durée du contact ont un effet positif et significatif sur la probabilité de souscription. D'autre part, des variables telles que la présence d'un prêt immobilier, d'un prêt personnel, ainsi que le nombre de contacts dans la campagne actuelle, réduisent cette probabilité. L'âge, similaire au modèle Probit, n'a pas d'effet statistiquement significatif.

Le McFadden R-squared du modèle Logit est de 0.242550, ce qui indique que le modèle explique environ 24.3% de la variance observée. La statistique du test de vraisemblance (LR Statistic) de 783.6789 (avec une p-value inférieure à 0.0000) confirme la significativité globale du modèle, suggérant qu'il est bien adapté pour expliquer les facteurs influençant la souscription à un dépôt à terme. Ces résultats sont cohérents avec ceux obtenus par le modèle Probit, renforçant la robustesse de l'analyse.

6.4.3 Selection du meilleur modèle

Pour choisir entre un modèle Probit et un modèle Logit, il faut prendre en compte plusieurs facteurs, notamment la nature des données, l'interprétation des résultats et les critères statistiques. Les deux modèles sont bien adaptés aux variables dépendantes binaires, et leurs performances sont assez similaires dans votre cas, avec des valeurs de McFadden R-squared proches (0.246 pour Probit et 0.242 pour Logit).

Cependant, il y a quelques différences à considérer. Le modèle Logit est souvent préféré car il est plus facile à interpréter. En effet, ses coefficients sont directement liés aux odds ratios, ce qui facilite l'interprétation des effets des variables indépendantes sur la probabilité de l'événement. De plus, le modèle Logit est généralement plus simple à expliquer à un public non spécialisé.

Le modèle Probit, en revanche, utilise une fonction de distribution normale cumulative, ce qui peut le rendre plus approprié si vous souhaitez capturer une structure plus précise dans certains contextes théoriques. Cependant, ses coefficients sont plus difficiles à interpréter directement, ce qui peut compliquer l'analyse pour des utilisateurs moins familiers avec la statistique avancée. Bien que les deux modèles donnent des résultats similaires, le modèle Logit est souvent préféré en raison de sa simplicité d'interprétation, de sa robustesse et de son large usage dans la pratique.

6.5 Conclusion

Cette étude a exploré l'utilisation de modèles économétriques Probit et Logit pour prédire la probabilité de souscription aux dépôts à terme dans le cadre d'une campagne de marketing direct bancaire. En analysant un ensemble de données détaillé provenant d'une banque portugaise, nous avons évalué les corrélations entre différentes variables explicatives et identifié les déterminants clés de la souscription.

Les résultats de l'analyse de corrélation ont révélé une multicolinéarité modérée entre certaines variables, nécessitant une sélection judicieuse pour minimiser les biais dans les modèles. Les variables comme l'âge, l'éducation, le solde annuel moyen, la durée des contacts, et le nombre de contacts durant la campagne ont été retenues pour leur pertinence et leur faible corrélation entre elles. Par contre, nous avons choisi de ne conserver qu'une seule variable parmi 'pdays', 'previous', et 'poutcome' pour éviter la redondance, optant pour 'previous'.

Les modèles Probit et Logit ont montré des performances similaires en termes de McFadden R-squared, avec des valeurs autour de 24%, indiquant une capacité raisonnable à expliquer la variance dans la souscription. Le modèle Logit a été légèrement favorisé pour son interprétabilité plus directe via les odds ratios. Les résultats des deux modèles soulignent l'importance de la durée des contacts, du type de communication utilisé, et du niveau d'éducation dans la prédiction de la souscription. A contrario, le nombre de contacts pendant la campagne actuelle semble avoir un effet négatif, potentiellement dû à la lassitude des clients contactés à plusieurs reprises.

En conclusion, cette analyse apporte des éclaircissements sur les facteurs qui influencent la décision de souscription à un dépôt à terme, offrant ainsi des pistes pour optimiser les stratégies de marketing direct. Les institutions bancaires peuvent utiliser ces informations pour cibler plus efficacement leurs campagnes, en se concentrant sur des caractéristiques et des interactions spécifiques avec les clients. Pour des prédictions encore plus précises, des recherches futures pourraient intégrer des variables supplémentaires ou explorer des techniques de machine learning plus avancées pour compléter ces modèles économétriques traditionnels.

7 Bibliographie/Webographie

Bourbonnais, R., & Terrazza, M. (2010). *Analyse des séries temporelles : Applications à l'économie et à la gestion*, 3^{eme} éd. DUNOD, Paris.

Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.

Gujarati, D. N., & Porter, D. C. (2009). *Basic Econometrics*. McGraw-Hill.

Engle, R. F., & Granger, C. W. J. (1987). *Co-integration and Error Correction: Representation, Estimation, and Testing*. *Econometrica*, 55(2), 251–276.


Sims, C. A. (1980). *Macroeconomics and Reality*. *Econometrica*, 48(1), 1–48.

International Energy Agency (2024). *Oil Market Report*. www.iea.org.

Bloomberg Terminal (2024). *Cours de l'action Total, CAC40 et Brent*. www.bloomberg.com.

UCI Machine Learning Repository : <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>

8 Annexes



Source : R. Bourbonnais, M. Terraza, « Analyse des séries temporelles », 3^{ème} édition

Figure 9: Procédure d'identification de processus générateur




Figure 10: le Corrélograme: LTOTAL




Figure 11: Jarque Berra: LTOTAL

Null Hypothesis: LTOTAL has a unit root		
Exogenous: Constant, Linear Trend		
Bandwidth: 2 (Newey-West automatic) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-1.942187	0.6266
Test critical values: 1% level	-4.030729	
5% level	-3.445030	
10% level	-3.147382	
*MacKinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.004256
HAC corrected variance (Bartlett kernel)		0.003565

Figure 12: modèle 3 constante et tendance

Null Hypothesis: LTOTAL has a unit root		
Exogenous: Constant		
Bandwidth: 2 (Newey-West automatic) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-1.694203	0.4318
Test critical values: 1% level	-3.481623	
5% level	-2.883930	
10% level	-2.578788	
*MacKinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.004295
HAC corrected variance (Bartlett kernel)		0.003585

Figure 13: modèle 2 constante et sans tendance

Null Hypothesis: LTOTAL has a unit root		
Exogenous: None		
Bandwidth: 8 (Newey-West automatic) using Bartlett kernel		
	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	0.574560	0.8392
Test critical values: 1% level	-2.583011	
5% level	-1.943324	
10% level	-1.615075	
*MacKinnon (1996) one-sided p-values.		
Residual variance (no correction)		0.004420
HAC corrected variance (Bartlett kernel)		0.002897

Figure 14: modèle 1 sans constante et sans tendance

BDS Test for TOTAL
Date: 10/13/24 Time: 21:32
Sample: 2014M01 2024M10
Included observations: 130

Dimension	BDS Statistic	Std. Error	z-Statistic	Prob.
2	0.137678	0.006443	21.36967	0.0000
3	0.235191	0.010258	22.92657	0.0000
4	0.293722	0.012237	24.00215	0.0000
5	0.325970	0.012776	25.51337	0.0000
6	0.343327	0.012342	27.81797	0.0000

Figure 15: test BDS

Dependent Variable: DLTOTAL
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)
Date: 10/13/24 Time: 21:47
Sample (adjusted): 2014M02 2024M10
Included observations: 129 after adjustments
Convergence achieved after 10 iterations
Coefficient covariance computed using outer product of gradients
Presample variance: backcast (parameter = 0.7)
GARCH = C(2) + C(3)*RESID(-1)^2

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.002555	0.004913	0.520054	0.6030
Variance Equation				
C	0.002883	0.000505	5.705642	0.0000
RESID(-1)^2	0.382528	0.112468	3.401211	0.0007
R-squared	-0.000053	Mean dependent var		0.003037
Adjusted R-squared	-0.000053	S.D. dependent var		0.066724
S.E. of regression	0.066726	Akaike info criterion		-2.621563
Sum squared resid	0.569904	Schwarz criterion		-2.555056
Log likelihood	172.0908	Hannan-Quinn criter.		-2.594540
Durbin-Watson stat	2.168100			

Figure 16: Modèle ARCH (1)

Heteroskedasticity Test: ARCH

F-statistic	0.387833	Prob. F(6,116)	0.8856
Obs*R-squared	2.418899	Prob. Chi-Square(6)	0.8774

Figure 17: Test ARCH sur modèle ARCH (1)

Heteroskedasticity Test: ARCH

F-statistic	65.78984	Prob. F(5,119)	0.0000
Obs*R-squared	91.79311	Prob. Chi-Square(5)	0.0000

Résultats du Test d'hétéroscédasticité de la série Total

Figure 18: Résultats du Test d'hétéroscédasticité de la série Total

Mois/Année	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	Moyenne	Ecart Type
Janvier	1,626750854	1,658011397	1,611935625	1,668944734	1,668865415	1,681060244	1,644930708	1,542825427	1,700876708	1,755722445	1,655972356	0,056417799
Février	1,672374979	1,683317262	1,616790486	1,672559628	1,67182056	1,698883137	1,58410497	1,58410497	1,658869592	1,767675224	1,661050081	0,055254543
Mars	1,677606953	1,665299499	1,602710945	1,675869955	1,663983455	1,694780636	1,548880663	1,599555591	1,663040975	1,735279448	1,652708802	0,053998001
Avril	1,711638538	1,685562611	1,642761203	1,673665876	1,718750735	1,695043659	1,516535374	1,566201719	1,674217946	1,762978491	1,664735615	0,073368401
Mai	1,711638538	1,662568967	1,640183192	1,674585602	1,716420734	1,668758542	1,526597709	1,578753784	1,744996674	1,724930914	1,664943466	0,068420102
Juin	1,722469386	1,63918756	1,637289548	1,636287252	1,717753693	1,692582562	1,531223375	1,581608366	1,702171951	1,72057272	1,658114641	0,064937066
Juillet	1,682054777	1,653983907	1,631037697	1,633064273	1,747100931	1,672374979	1,495544338	1,564660604	1,696880372	1,742410881	1,651911822	0,077070257
Août	1,700617196	1,610660163	1,630936119	1,637989781	1,731346976	1,656960183	1,519827994	1,572174314	1,704922291	1,763951826	1,652938684	0,074684434
Septembre	1,711385379	1,604226053	1,625003601	1,657533888	1,74694541	1,680154142	1,465382851	1,616370472	1,683677299	1,794557751	1,658523685	0,090290698
Octobre	1,675961553	1,644930708	1,640680153	1,680063427	1,715669142	1,67329744	1,411956238	1,637189422	1,741151599	1,800717078	1,662161676	0,101609114
Novembre	1,653115993	1,672097858	1,652729696	1,675869955	1,691611874	1,677971753	1,554246808	1,606632989	1,780389328	1,794209116	1,676087537	0,071149804
Décembre	1,628593256	1,615634469	1,687707728	1,663229635	1,664453929	1,691965103	1,547774705	1,649626887	1,768268016	1,789580712	1,670683399	0,070591395
Moyenne	1,68118395	1,649623371	1,634980462	1,662472001	1,704543571	1,681986031	1,528917136	1,591809167	1,709955229	1,762715551	1,660818647	
Ecart type	0,032311279	0,02746888	0,021857557	0,017212472	0,031255883	0,01286657	0,057979153	0,031420665	0,040090935	0,027986099		0,069653106

Figure 19: Tableau Buys-Ballot de la série LTtotal

	1er	2ème	3ème	4ème	5ème	6ème	7ème	8ème	9ème	10ème	11ème	12ème
2014	Juin	Avril	Mai	Septembre	Août	Juillet	Mars	Octobre	Février	Novembre	Décembre	Janvier
2015	Avril	Février	Novembre	Mars	Mai	Janvier	Juillet	Octobre	Juin	Décembre	Août	Septembre
2016	Décembre	Novembre	Avril	Octobre	Mai	Juin	Juillet	Août	Septembre	Février	Janvier	Mars
2017	Octobre	Novembre	Mars	Mai	Avril	Février	Janvier	Décembre	Septembre	Août	Juin	Juillet
2018	Juillet	Septembre	Août	Avril	Juin	Mai	Octobre	Novembre	Février	Janvier	Décembre	Mars
2019	Février	Avril	Mars	Juin	Décembre	Janvier	Septembre	Novembre	Octobre	Juillet	Mai	Août
2020	Janvier	Février	Novembre	Mars	Décembre	Juin	Mai	Août	Avril	Juillet	Septembre	Octobre
2021	Décembre	Octobre	Septembre	Novembre	Mars	Février	Juin	Mai	Août	Avril	Juillet	Janvier
2022	Novembre	Décembre	Mai	Octobre	Août	Juin	Janvier	Juillet	Septembre	Avril	Mars	Février
2023	Octobre	Septembre	Novembre	Décembre	Février	Août	Avril	Janvier	Juillet	Mars	Mai	Juin

Figure 20: Tableau Buys-Ballot classé de la série Lttotal

	Source des variations	Somme des carrés	Degré de liberté	Moyenne des carrés	F	Probabilité	Valeur critique pour F
Mois		0,006080562	11	0,000552778	0,502443271	0,897544471	1,886683603
Année		0,462336622	9	0,051370736	46,69300108	9,81032E-32	1,975806073
Erreur		0,108917883	99	0,001100181			
Total		0,577335068	119				

Figure 21: Résumé du tableau de l'analyse de la variance de la série Lttotal

Dependent Variable: DLTOTAL
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 11/17/24 Time: 16:34
Sample: 2014M02 2024M10
Included observations: 129
Convergence achieved after 23 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.904478	0.204608	-4.420550	0.0000
AR(2)	-0.262671	0.103377	-2.540897	0.0123
AR(3)	-0.052502	0.134105	-0.391499	0.6961
MA(1)	0.832824	0.202037	4.122134	0.0001
SIGMASQ	0.004130	0.000434	9.519442	0.0000
R-squared	0.065148	Mean dependent var		0.003037
Adjusted R-squared	0.034992	S.D. dependent var		0.066724
S.E. of regression	0.065547	Akaike info criterion		-2.572397
Sum squared resid	0.532748	Schwarz criterion		-2.461552
Log likelihood	170.9196	Hannan-Quinn criter.		-2.527358
Durbin-Watson stat	1.975661			
Inverted AR Roots	-.14-.25i	-.14+.25i	-.62	
Inverted MA Roots	-.83			

Figure 22: ARMA(3,1)

Dependent Variable: DLTOTAL
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 11/17/24 Time: 16:30
Sample: 2014M02 2024M10
Included observations: 129
Failure to improve objective (non-zero gradients) after 46 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.215404	0.090164	-2.389020	0.0184
AR(2)	-1.064418	0.105688	-10.07130	0.0000
AR(3)	-0.022495	0.096205	-0.233829	0.8155
AR(4)	-0.229347	0.107249	-2.138446	0.0345
MA(1)	0.130309	3.310683	0.039360	0.9687
MA(2)	0.999999	50.79179	0.019688	0.9843
SIGMASQ	0.003681	0.093236	0.039476	0.9686
R-squared	0.166838	Mean dependent var		0.003037
Adjusted R-squared	0.125862	S.D. dependent var		0.066724
S.E. of regression	0.062384	Akaike info criterion		-2.619174
Sum squared resid	0.474798	Schwarz criterion		-2.463990
Log likelihood	175.9367	Hannan-Quinn criter.		-2.556120
Durbin-Watson stat	1.968443			
Inverted AR Roots	.04-.53i	.04+.53i	-.15+.88i	-.15-.88i
Inverted MA Roots	-.07+1.00i	-.07-1.00i		

Figure 23: ARMA(4,2)

Dependent Variable: DLTOTAL
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 11/17/24 Time: 16:30
Sample: 2014M02 2024M10
Included observations: 129
Convergence achieved after 82 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.267885	0.090836	-2.949110	0.0038
AR(2)	-0.817702	0.068085	-12.00993	0.0000
MA(1)	0.199450	3.493597	0.057090	0.9546
MA(2)	0.729735	16.76335	0.043532	0.9653
MA(3)	0.030189	1.286277	0.023470	0.9813
MA(4)	-0.279147	21.03018	-0.013274	0.9894
SIGMASQ	0.003666	0.061884	0.059244	0.9529
R-squared	0.170088	Mean dependent var		0.003037
Adjusted R-squared	0.129273	S.D. dependent var		0.066724
S.E. of regression	0.062262	Akaike info criterion		-2.623971
Sum squared resid	0.472945	Schwarz criterion		-2.468787
Log likelihood	176.2461	Hannan-Quinn criter.		-2.560917

Figure 24: ARMA(2,4)

Dependent Variable: DLTOTAL
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 11/17/24 Time: 16:10
Sample: 2014M02 2024M10
Included observations: 129
Convergence achieved after 33 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.799792	0.188199	-4.249705	0.0000
AR(2)	-0.235634	0.074674	-3.155491	0.0020
MA(1)	0.732160	0.184802	3.961860	0.0001
SIGMASQ	0.004135	0.000428	9.672325	0.0000
R-squared	0.063924	Mean dependent var	0.003037	
Adjusted R-squared	0.041458	S.D. dependent var	0.066724	
S.E. of regression	0.065327	Akaike info criterion	-2.586803	
Sum squared resid	0.533445	Schwarz criterion	-2.498126	
Log likelihood	170.8488	Hannan-Quinn criter.	-2.550772	
Durbin-Watson stat	1.987646			
Inverted AR Roots	-.40+.28i	-.40-.28i		
Inverted MA Roots	-.73			

Figure 25: ARMA(2,1)

Chapitre 2 : Etude multivariée des cours de l'action Total, du Brent et du CAC40

ANALYSE DE VARIANCE BRENT						
Source des variations	Somme des carrés	Degré de liberté	Moyenne des carrés	F	Probabilité	Valeur critique pour F
Lignes	975,6582067	11	88,69620061	0,9727788	0,476152514	1,886683603
Colonnes	44365,13316	9	4929,45924	54,064025	2,79232E-34	1,975806073
Erreur	9026,639577	99	91,17817754			
Total	54367,43095	119				

Figure 26: Analyse de la variance brent

Heteroskedasticity Test: ARCH

F-statistic	329.8858	Prob. F(1,127)	0.0000
Obs*R-squared	93.14203	Prob. Chi-Square(1)	0.0000

Figure 27: test d'hétéroscédasticité brent

ANALYSE DE VARIANCE CAC40						
Source des variations	Somme des carrés	Degré de liberté	Moyenne des carrés	F	Probabilité	Valeur critique pour F
Lignes	981884,4292	11	89262,22084	1,02932028	0,426800263	1,886683603
Colonnes	96477170,89	9	10719685,65	123,6132122	9,22519E-50	1,975806073
Erreur	8585238,27	99	86719,57848			
Total	106044293,6	119				

Figure 28: analyse de la variance du CAC 40

Heteroskedasticity Test: ARCH

F-statistic	686.5098	Prob. F(1,127)	0.0000
Obs*R-squared	108.8613	Prob. Chi-Square(1)	0.0000

Figure 29: test d'hétéroscédasticité CAC 40

Null Hypothesis: LBRENT has a unit root

Exogenous: Constant, Linear Trend

Lag Length: 1 (Automatic - based on AIC, maxlag=12)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.163515	0.0966
Test critical values:		
1% level	-4.031309	
5% level	-3.445308	
10% level	-3.147545	

Figure 30: Calcul T-stat modèle 6

Dependent Variable: D(LBRENT)

Method: Least Squares

Date: 01/19/25 Time: 02:53

Sample (adjusted): 2014M03 2024M10

Included observations: 128 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-0.002164	0.010418	-0.207717	0.8358
D(LBRENT(-1))	0.145081	0.088321	1.642655	0.1029
R-squared	0.020966	Mean dependent var		-0.002611
Adjusted R-squared	0.013196	S.D. dependent var		0.118611
S.E. of regression	0.117826	Akaike info criterion		-1.423720
Sum squared resid	1.749243	Schwarz criterion		-1.379157
Log likelihood	93.11808	Hannan-Quinn criter.		-1.405614
F-statistic	2.698314	Durbin-Watson stat		1.971788
Prob(F-statistic)	0.102948			

Figure 31: calcul SCRD

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(LBRENT)
Method: Least Squares
Date: 01/19/25 Time: 02:52
Sample (adjusted): 2014M03 2024M10
Included observations: 128 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LBRENT(-1)	-0.107193	0.033884	-3.163515	0.0020
D(LBRENT(-1))	0.182408	0.086621	2.105809	0.0372
C	0.415432	0.138040	3.009505	0.0032
@TREND("2014M01")	0.000485	0.000286	1.694670	0.0926
R-squared	0.098326	Mean dependent var	-0.002611	
Adjusted R-squared	0.076512	S.D. dependent var	0.118611	
S.E. of regression	0.113983	Akaike info criterion	-1.474784	
Sum squared resid	1.611024	Schwarz criterion	-1.385658	
Log likelihood	98.38614	Hannan-Quinn criter.	-1.438571	
F-statistic	4.507344	Durbin-Watson stat	1.991235	
Prob(F-statistic)	0.004891			

Figure 32: calcul SCR6

Dependent Variable: D(LBRENT)
Method: Least Squares
Date: 01/19/25 Time: 03:24
Sample (adjusted): 2014M03 2024M10
Included observations: 128 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
D(LBRENT(-1))	0.145561	0.087958	1.654895	0.1004
R-squared	0.020631	Mean dependent var	-0.002611	
Adjusted R-squared	0.020631	S.D. dependent var	0.118611	
S.E. of regression	0.117381	Akaike info criterion	-1.439003	
Sum squared resid	1.749842	Schwarz criterion	-1.416721	
Log likelihood	93.09617	Hannan-Quinn criter.	-1.429950	
Durbin-Watson stat	1.971990			

Figure 33: calcul SCRC

Null Hypothesis: LBRENT has a unit root
 Exogenous: Constant
 Lag Length: 1 (Automatic - based on AIC, maxlag=12)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-2.766264	0.0660
Test critical values: 1% level	-3.482035	
5% level	-2.884109	
10% level	-2.578884	

*Mackinnon (1996) one-sided p-values.

Figure 34: Calcul T-stat modèle 5

Augmented Dickey-Fuller Test Equation
 Dependent Variable: D(LBRENT)
 Method: Least Squares
 Date: 01/26/25 Time: 18:14
 Sample (adjusted): 2014M03 2024M10
 Included observations: 128 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
LBRENT(-1)	-0.090205	0.032609	-2.766264	0.0065
D(LBRENT(-1))	0.184633	0.087258	2.115948	0.0363
C	0.375990	0.137079	2.742879	0.0070
R-squared	0.077443	Mean dependent var	-0.002611	
Adjusted R-squared	0.062682	S.D. dependent var	0.118611	
S.E. of regression	0.114833	Akaike info criterion	-1.467512	
Sum squared resid	1.648336	Schwarz criterion	-1.400668	
Log likelihood	96.92077	Hannan-Quinn criter.	-1.440353	
F-statistic	5.246495	Durbin-Watson stat	1.983862	
Prob(F-statistic)	0.006487			

Figure 35: calcul SCR5

Null Hypothesis: LBRENT has a unit root
 Exogenous: None
 Lag Length: 0 (Automatic - based on AIC, maxlag=12)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-0.405889	0.5356
Test critical values: 1% level	-2.583011	
5% level	-1.943324	
10% level	-1.615075	

Figure 36: Calcul T-stat modèle 4

	TOTAL	BRENT	CAC 40
Hétéroscédasticité	OUI	OUI	OUI
Tendance	OUI	OUI	OUI
Saisonnalité	NON	NON	NON

Akaike information criterion -8.019132
Schwarz criterion -7.751754

Akaike information criterion -7.942375
Schwarz criterion -7.472076

Akaike information criterion -7.897380
Schwarz criterion -7.222075

Akaike information criterion -7.794262
Schwarz criterion -6.911828

Akaike information criterion -7.677919
Schwarz criterion -6.586197

Figure 37: Retard Modèle VAR

Vector Autoregression Estimates
Date: 01/19/25 Time: 18:44
Sample (adjusted): 1/03/2014 1/10/2024
Included observations: 128 after adjustments
Standard errors in () & t-statistics in []

	DLTOTAL	DLCAC40	DLBRENT
DLTOTAL(-1)	-0.192359 (0.11777) [-1.63337]	-0.092185 (0.08394) [-1.09826]	0.011505 (0.21096) [0.05454]
DLCAC40(-1)	0.042087 (0.16727) [0.25161]	-0.026102 (0.11922) [-0.21894]	0.233782 (0.29964) [0.78020]
DLBRENT(-1)	0.091493 (0.05776) [1.58389]	0.033151 (0.04117) [0.80522]	0.098770 (0.10348) [0.95453]
C	0.002809 (0.00589) [0.47702]	0.004453 (0.00420) [1.06098]	-0.003443 (0.01055) [-0.32634]

Figure 38: Estimation du VAR 1

Variance Decomposition of DLBRENT:				
Period	S.E.	DLTOTAL	DLCAC40	DLBRENT
1	0.118331	22.91434	5.264051	71.82161
2	0.120008	23.47864	6.011346	70.51001
3	0.120028	23.47086	6.018544	70.51060
4	0.120028	23.47131	6.018597	70.51009
5	0.120028	23.47131	6.018598	70.51009
6	0.120028	23.47131	6.018598	70.51009
7	0.120028	23.47131	6.018598	70.51009
8	0.120028	23.47131	6.018598	70.51009
9	0.120028	23.47131	6.018598	70.51009
10	0.120028	23.47131	6.018598	70.51009

Variance Decomposition of DLBRENT:				
Period	S.E.	DLTOTAL	DLCAC40	DLBRENT
1	0.118331	22.91434	5.264051	71.82161
2	0.120008	23.47864	6.011346	70.51001
3	0.120028	23.47086	6.018544	70.51060
4	0.120028	23.47131	6.018597	70.51009
5	0.120028	23.47131	6.018598	70.51009
6	0.120028	23.47131	6.018598	70.51009
7	0.120028	23.47131	6.018598	70.51009
8	0.120028	23.47131	6.018598	70.51009
9	0.120028	23.47131	6.018598	70.51009
10	0.120028	23.47131	6.018598	70.51009

Variance Decomposition of DLCAC40:				
Period	S.E.	DLTOTAL	DLCAC40	DLBRENT
1	0.047081	38.07791	61.92209	0.000000
2	0.047460	38.57006	60.93925	0.490692
3	0.047477	38.59963	60.89385	0.506523
4	0.047478	38.60073	60.89185	0.507423
5	0.047478	38.60078	60.89176	0.507459
6	0.047478	38.60079	60.89175	0.507461
7	0.047478	38.60079	60.89175	0.507461
8	0.047478	38.60079	60.89175	0.507461
9	0.047478	38.60079	60.89175	0.507461
10	0.047478	38.60079	60.89175	0.507461

Figure 39: Décomposition de la variance des trois séries

VAR Granger Causality/Block Exogeneity Wald Tests
Date: 01/19/25 Time: 18:56
Sample: 1/01/2014 1/10/2024
Included observations: 128

Dependent variable: DLTOTAL

Excluded	Chi-sq	df	Prob.
DLCAC40	0.063305	1	0.8013
DLBRENT	2.508711	1	0.1132
All	2.951600	2	0.2286

Dependent variable: DLCAC40

Excluded	Chi-sq	df	Prob.
DLTOTAL	1.206181	1	0.2721
DLBRENT	0.648384	1	0.4207
All	1.510045	2	0.4700

Dependent variable: DLBRENT

Excluded	Chi-sq	df	Prob.
DLTOTAL	0.002974	1	0.9565
DLCAC40	0.608719	1	0.4353
All	0.925443	2	0.6296

Figure 40: Ordre de décomposition de Cholesky

Pairwise Granger Causality Tests
Date: 01/19/25 Time: 19:28
Sample: 1/01/2014 1/10/2024
Lags: 1

Null Hypothesis:	Obs	F-Statistic	Prob.
DLCAC40 does not Granger Cause DLTOTAL	128	0.43761	0.5095
DLTOTAL does not Granger Cause DLCAC40		0.86409	0.3544
DLBRENT does not Granger Cause DLTOTAL	128	2.91010	0.0905
DLTOTAL does not Granger Cause DLBRENT		0.31772	0.5740
DLBRENT does not Granger Cause DLCAC40	128	0.30336	0.5828
DLCAC40 does not Granger Cause DLBRENT		0.92989	0.3368

Figure 41: Causalité de Granger





Figure 42: Fonctions de réponses impulsionnelles

VAR Residual Covariance Matrix				
	DLTOTAL	DLSP500	DLBRENT	
DLTO...	0.004353	0.000851	0.003776	
DLSP500	0.000851	0.001834	0.002286	
DLBR...	0.003776	0.002286	0.014033	

Figure 43: Matrice de covariance Sims

Chapitre 3: Étude sur les Déterminants de Souscription aux Dépôts à Termes



Dependent Variable: Y
Method: ML - Binary Logit (Newton-Raphson / Marquardt steps)
Date: 01/25/25 Time: 00:54
Sample: 1 4521
Included observations: 4521
Convergence achieved after 7 iterations
Coefficient covariance computed using observed Hessian

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	-4.670587	0.349321	-13.37048	0.0000
HOUSING	-0.671225	0.112741	-5.953695	0.0000
LOAN	-0.892773	0.187221	-4.768555	0.0000
CONTACT_CELLULAR	1.291009	0.169856	7.600619	0.0000
CONTACT_TELEPHO...	1.289856	0.256100	5.036526	0.0000
EDUCATION	0.220267	0.071327	3.088142	0.0020
DURATION	0.003964	0.000189	20.92211	0.0000
CAMPAIGN	-0.103564	0.027089	-3.823133	0.0001
PREVIOUS	0.124660	0.023317	5.346385	0.0000
AGE	0.008123	0.004972	1.633662	0.1023
BALANCE	7.24E-06	1.63E-05	0.444781	0.6565
McFadden R-squared	0.242550	Mean dependent var	0.115240	
S.D. dependent var	0.319347	S.E. of regression	0.284866	
Akaike info criterion	0.546189	Sum squared resid	365.9808	
Schwarz criterion	0.561801	Log likelihood	-1223.661	
Hannan-Quinn criter.	0.551689	Deviance	2447.321	
Restr. deviance	3231.000	Restr. log likelihood	-1615.500	
LR statistic	783.6789	Avg. log likelihood	-0.270662	
Prob(LR statistic)	0.000000			
Obs with Dep=0	4000	Total obs	4521	
Obs with Dep=1	521			

Figure 44: Regression Logit

Dependent Variable: Y
Method: ML - Binary Logit (Newton-Raphson / Marquardt steps)
Date: 01/25/25 Time: 00:55
Sample: 1 4521
Included observations: 4521
Convergence achieved after 8 iterations
Coefficient covariance computed using observed Hessian

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	-4.256228	0.244086	-17.43739	0.0000
HOUSING	-0.708759	0.110538	-6.411918	0.0000
LOAN	-0.906321	0.187001	-4.846617	0.0000
CONTACT_CELLULAR	1.290221	0.169801	7.598452	0.0000
CONTACT_TELEPHO...	1.361285	0.251890	5.404277	0.0000
EDUCATION	0.196235	0.069584	2.820107	0.0048
DURATION	0.003969	0.000190	20.94226	0.0000
CAMPAIGN	-0.104131	0.027064	-3.847653	0.0001
PREVIOUS	0.124637	0.023254	5.359826	0.0000
McFadden R-squared	0.241630	Mean dependent var	0.115240	
S.D. dependent var	0.319347	S.E. of regression	0.284941	
Akaike info criterion	0.545962	Sum squared resid	366.3352	
Schwarz criterion	0.558735	Log likelihood	-1225.146	
Hannan-Quinn criter.	0.550461	Deviance	2450.292	
Restr. deviance	3231.000	Restr. log likelihood	-1615.500	
LR statistic	780.7079	Avg. log likelihood	-0.270990	
Prob(LR statistic)	0.000000			
Obs with Dep=0	4000	Total obs	4521	
Obs with Dep=1	521			

Figure 45: Regression Logit 2

Dependent Variable: Y
Method: ML - Binary Probit (Newton-Raphson / Marquardt steps)
Date: 01/25/25 Time: 00:48
Sample: 1 4521
Included observations: 4521
Convergence achieved after 6 iterations
Coefficient covariance computed using observed Hessian

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	-2.536026	0.177721	-14.26974	0.0000
HOUSING	-0.342101	0.059114	-5.787164	0.0000
LOAN	-0.453156	0.094788	-4.780742	0.0000
CONTACT_CELLULAR	0.638891	0.083606	7.641647	0.0000
CONTACT_TELEPHO...	0.651418	0.130175	5.004174	0.0000
AGE	0.004058	0.002614	1.552366	0.1206
EDUCATION	0.116405	0.037595	3.096248	0.0020
BALANCE	5.64E-06	9.03E-06	0.624682	0.5322
DURATION	0.002103	9.26E-05	22.70999	0.0000
CAMPAIGN	-0.057328	0.014258	-4.020692	0.0001
PREVIOUS	0.070064	0.012988	5.394590	0.0000
McFadden R-squared	0.246144	Mean dependent var	0.115240	
S.D. dependent var	0.319347	S.E. of regression	0.284533	
Akaike info criterion	0.543621	Sum squared resid	365.1244	
Schwarz criterion	0.559233	Log likelihood	-1217.854	
Hannan-Quinn criter.	0.549120	Deviance	2435.709	
Restr. deviance	3231.000	Restr. log likelihood	-1615.500	
LR statistic	795.2914	Avg. log likelihood	-0.269377	
Prob(LR statistic)	0.000000			
Obs with Dep=0	4000	Total obs	4521	
Obs with Dep=1	521			

Figure 46: Regression Probit

Dependent Variable: Y
Method: ML - Binary Probit (Newton-Raphson / Marquardt steps)
Date: 01/25/25 Time: 00:51
Sample: 1 4521
Included observations: 4521
Convergence achieved after 7 iterations
Coefficient covariance computed using observed Hessian

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	-2.327354	0.122024	-19.07294	0.0000
HOUSING	-0.360331	0.058086	-6.203421	0.0000
LOAN	-0.460736	0.094712	-4.864600	0.0000
CONTACT_CELLULAR	0.640774	0.083648	7.660328	0.0000
CONTACT_TELEPHO...	0.689809	0.127843	5.395740	0.0000
EDUCATION	0.104527	0.036678	2.849819	0.0044
DURATION	0.002104	9.26E-05	22.73227	0.0000
CAMPAIGN	-0.057795	0.014256	-4.054170	0.0001
PREVIOUS	0.070065	0.012970	5.401926	0.0000
McFadden R-squared	0.245219	Mean dependent var	0.115240	
S.D. dependent var	0.319347	S.E. of regression	0.284620	
Akaike info criterion	0.543397	Sum squared resid	365.5118	
Schwarz criterion	0.556170	Log likelihood	-1219.349	
Hannan-Quinn criter.	0.547897	Deviance	2438.697	
Restr. deviance	3231.000	Restr. log likelihood	-1615.500	
LR statistic	792.3030	Avg. log likelihood	-0.269708	
Prob(LR statistic)	0.000000			
Obs with Dep=0	4000	Total obs	4521	
Obs with Dep=1	521			

Figure 47: Regression Probit 2

Table des matières

1	Sommaire	1
2	REMERCIEMENTS	2
3	RESUME	3
4	Chapitre 1 : Etude univariée du cours de l'action Total	4
4.1	INTRODUCTION	4
4.2	ANALYSE DU COURS DE L'ACTION TOTAL	5
4.2.1	Analyse descriptive	5
4.2.2	Test d'hétéroscédasticité	6
4.2.3	Analyse de la saisonnalité et de la tendance	8
4.3	PREVISION	9
4.3.1	Test de Stationnarité Dickey-Fuller	9
4.3.2	Test de Phillips-Perron	11
4.3.3	Test BDS	12
4.3.4	Identification du processus	13
4.3.5	Prévision du cours de l'action Total	15
4.4	Conclusion	17
5	Chapitre 2 : Etude multivariée des cours de l'action Total, du Brent et du CAC40	18
5.1	Introduction	18
5.2	Analyse des chroniques	18
5.2.1	Test d'hétéroscédasticité et analyse de la variance	20
5.3	Le modèle Vector Auto Regressive (VAR)	24
5.4	Causalité au sens de Granger	29
5.5	Causalité au sens de Sims	30
5.6	Modèle à Correction d'Erreurs Vectoriel (VECM)	32
5.7	Conclusion	33
6	Chapitre 3: Étude sur les Déterminants de Souscription aux Dépôts à Termes	35
6.1	Introduction	35
6.2	Données et Analyse Descriptives	35
6.3	Analyse de la Corrélation entre les variables	39
6.3.1	Variables Numériques	39
6.3.2	Variables Categorielles	40
6.4	Modélisation	41
6.4.1	Régression modèle Probit	42
6.4.2	Regression du Modèle Logit	43
6.4.3	Selection du meilleur modèle	44
6.5	Conclusion	45
7	Bibliographie/Webographie	46
8	Annexes	47